



دانشگاه صنعتی شریف

دانشکده مهندسی صنایع

درس: فناوری اطلاعات (۲۱۷۷۶)

نیمسال دوم سال تحصیلی ۱۴۰۴ - ۱۴۰۵

گزارش پروژه

استاد: سرکار خانم دکتر مریم بستان آرا

نگارش:

رامتین فلاح: ۴۰۳۱۰۴۶۹۱

امیرعلی شهسواری: ۴۰۳۱۰۴۵۴۸

امیرعلی زلیکانی: ۴۰۳۱۰۴۴۴۲

تیر ۱۴۰۵

فهرست مطالب

۱ فاز صفر

۱	تحلیل مدل کسب و کار پایگاه داده نورثویند	۱.۱
۱	ماهیت کسب و کار و ساختار سازمان به سازمان	۱.۱.۱
۱	نوع محصولات و زنجیره تأمین بین المللی	۲.۱.۱
۱	ارکان اصلی سیستم	۳.۱.۱
۲	چرخه عملیاتی کسب و کار	۴.۱.۱
۲	ساختار معماری داده ها و ارتباطات	۲.۱
۳	تعریف شاخص های کلیدی عملکرد	۳.۱
۳	حوزه فروش و درآمد	۱.۳.۱
۳	حوزه عملیات و لجستیک	۲.۳.۱
۴	حوزه مشتریان و کارکنان	۳.۳.۱

۲ فاز اول

۵	پیش پردازش و پاک سازی داده ها	۱.۲
۱۳	مهندسی ویژگی ها و آماده سازی جهت تحلیل	۲.۲
۱۶	شناسایی و مدیریت داده های پرت	۳.۲
۲۰	اعتبارسنجی داده ها	۴.۲

۳ فاز دوم

۲۵	اعتبارسنجی داده ها	۱.۳
۲۷	پاک سازی و تبدیل داده ها با ابزار کوئری سازی	۲.۳
۳۰	مدل سازی و تحلیل داده ها	۳.۳
۳۰	نمایش مقدار سفارش جدید برای هر دسته بندی در جدول محوری	۱.۳.۳
۳۰	تحلیل هزینه حمل به تفکیک کشور و شرکت حمل و نقل همراه با نمودار	۲.۳.۳
۳۱	تحلیل تقاضا و قیمت واحد کالا و نمایش بصری مقدار فروش هر کالا	۳.۳.۳
۳۱	تحلیل ارزش کل موجودی انبار به تفکیک تأمین کنندگان	۴.۳.۳
۳۲	تحلیل درآمد کل شرکت به تفکیک کشور مقصد با استفاده از برش گر و نمودار	۵.۳.۳

۴.۳ خودکارسازی با ماکرو و برنامه‌نویسی ۳۳

۴ فاز سوم ۳۵

۱.۴ طراحی جداول و روابط ۳۵

۲.۴ طراحی کوئری‌ها ۳۶

۱.۲.۴ نشان دادن نام محصول و قیمت نهایی آن پس از اعمال تخفیف ۳۶

۲.۲.۴ نشان دادن نام هر محصول به همراه تعداد کل سفارش‌ها ۳۷

۳.۲.۴ نشان دادن نام هر کارمند به همراه تعداد کل سفارش‌ها توسط او ۳۷

۳.۴ طراحی فرم‌های پایگاه داده ۳۸

۴.۴ طراحی گزارش‌های مدیریتی و تحلیلی ۴۲

۱.۴.۴ گزارش عملکرد و ارزش‌گذاری گروه‌های کالایی ۴۲

۲.۴.۴ گزارش تحلیل رفتار خرید مشتریان ۴۴

۱ فاز صفر

۱.۱ تحلیل مدل کسب و کار پایگاه داده نورثویند

بررسی دقیق ساختار جداول و داده‌های پایگاه داده نورثویند^۱ نشان می‌دهد که این سیستم متعلق به یک شرکت عمده‌فروش و توزیع‌کننده بین‌المللی در صنعت مواد غذایی است. ابعاد مختلف این مدل کسب و کار به شرح زیر است:

۱.۱.۱ ماهیت کسب و کار و ساختار سازمان به سازمان

شرکت نورثویند تولیدکننده نیست، بلکه به عنوان یک پل ارتباطی در زنجیره تأمین عمل می‌کند. بررسی اطلاعات جدول مشتریان^۲ نشان‌دهنده یک ساختار کاملاً تجاری و سازمان به سازمان^۳ است؛ وجود فیلدهایی نظیر ساختار حقوقی، نام شرکت‌ها و شماره نمابر^۴ برای اکثر مشتریان، اثبات می‌کند که خریداران این شرکت مصرف‌کنندگان نهایی نیستند.

۲.۱.۱ نوع محصولات و زنجیره تأمین بین‌المللی

محصولات ثبت شده در جداول دسته‌بندی‌ها^۵ و محصولات^۶ تماماً اقلام خوراکی و سوپرمارکتی هستند. داده‌های مکانی نشان می‌دهد که شرکت این محصولات را از تأمین‌کنندگان در کشورهای مختلف خریداری کرده و به دست مشتریانی در سراسر جهان می‌رساند که نشان‌دهنده یک شبکه گسترده و بین‌المللی لجستیک و تأمین است.

۳.۱.۱ ارکان اصلی سیستم

این مدل کسب و کار بر پنج رکن اصلی^۷ استوار است:

- **تأمین‌کنندگان**^۸: شرکت‌ها و تولیدکنندگان بین‌المللی که موجودی کالاهای نورثویند را تأمین می‌کنند.
- **مشتریان**^۹: شرکت‌ها و خریداران تجاری در مناطق جغرافیایی گوناگون که دریافت‌کننده نهایی کالاها هستند.
- **شرکت‌های حمل و نقل**^{۱۰}: شرکای لجستیکی واسطه که وظیفه انتقال فیزیکی کالا از انبارها به آدرس مشتریان را بر عهده دارند.

¹Northwind Database

²Customers.csv

³B2B (Business-to-Business)

⁴Fax

⁵Categories.csv

⁶Products.csv

⁷Core Entities

⁸Suppliers

⁹Customers

¹⁰Shippers

- **کارکنان^۱:** تیم فروش و مدیریت که مسئولیت رسیدگی به مشتریان و ثبت سفارش‌ها را در مناطق جغرافیایی مشخص^۲ بر عهده دارند.

- **محصولات و دسته‌بندی‌ها:** هسته اصلی تراکنش‌ها که شامل کاتالوگ کالاهای قابل فروش و گروه‌بندی آن‌ها می‌شود.

۴.۱.۱ چرخه عملیاتی کسب‌وکار

چرخه فعالیت در این شرکت از تأمین موجودی^۳ آغاز می‌شود؛ کالاها توسط تأمین‌کنندگان وارد سیستم شده و در دسته‌بندی‌های مشخص با قیمت‌گذاری معین ثبت می‌شوند. در مرحله بعد، مشتریان از طریق تیم فروش سفارش‌های^۴ خود را ثبت می‌کنند. سیستم، جزئیات هر سفارش شامل نوع کالا، تعداد و تخفیف‌های اعمال‌شده را پردازش کرده و در نهایت، محموله برای بسته‌بندی و ارسال به شرکت‌های حمل‌ونقل واگذار می‌شود تا کالا به دست مشتری نهایی برسد. این فرآیند، چرخه عملیاتی^۵ کامل شرکت را تشکیل می‌دهد.

۲.۱ ساختار معماری داده‌ها و ارتباطات

در جدول زیر، ساختار معماری داده‌ها، کلیدهای اصلی و خارجی، و ارتباطات بین جداول پایگاه داده نورث‌ویند شرح داده شده است:

نام جدول	کلید اصلی ^۶	کلیدهای خارجی ^۷	توضیحات و ارتباطات ^۸
Categories	CategoryID	- ندارد -	اطلاعات پایه‌ای دسته‌بندی محصولات
Suppliers	SupplierID	- ندارد -	اطلاعات تأمین‌کنندگان کالا
Products	ProductID	SupplierID, CategoryID	متصل به جداول تأمین‌کنندگان و دسته‌بندی‌ها
Customers	CustomerID	- ندارد -	اطلاعات مشتریان
Employees	EmployeeID	ReportsTo	فیلد ReportsTo به شناسه خود جدول Employees اشاره دارد (ارجاع به خود ^۹ برای چارت سازمانی)
Shippers	ShipperID	- ندارد -	اطلاعات شرکت‌های حمل‌ونقل و لجستیک
Orders	OrderID	CustomerID, EmployeeID, ShipVia	متصل به مشتری، کارمند ثبت‌کننده و شرکت حمل (فیلد ShipVia به ShipperID متصل است)
Order_Details	(OrderID, ProductID)	OrderID, ProductID	جدول واسطه: دارای کلید اصلی ترکیبی ^{۱۰}
Region	RegionID	- ندارد -	مناطق جغرافیایی کلان
Territories	TerritoryID	RegionID	حوزه‌های جغرافیایی خردتر، متصل به جدول Region
EmployeeTerritories	(EmployeeID, TerritoryID)	EmployeeID, TerritoryID	جدول واسطه: حل ارتباط چند-به-چند بین کارمندان و حوزه‌های کاری (کلید اصلی ترکیبی)
CustomerDemographics	CustomerTypeID	- ندارد -	گروه‌های دموگرافیک مشتریان
CustomerCustomerDemo	(CustomerID, CustomerTypeID)	CustomerID, CustomerTypeID	جدول واسطه: حل ارتباط چند-به-چند بین مشتریان و گروه‌های دموگرافیک

¹ Employees

² Territories

³ Inventory

⁴ Orders

⁵ Activity Cycle

⁶ Primary Key (PK)

⁷ Foreign Keys (FK)

⁸ Relation

⁹ Self-referencing

¹⁰ Composite Key

۳.۱ تعریف شاخص‌های کلیدی عملکرد^۱

بر اساس تحلیل مدل کسب‌وکار سازمان به‌سازمان شرکت نورث‌ویند، شاخص‌های کلیدی عملکرد در سه حوزه اصلی تدوین شده‌اند. تمامی این شاخص‌ها دارای منطق محاسباتی شفاف بوده و جهت پشتیبانی از تصمیم‌گیری‌های مدیریتی طراحی شده‌اند:

۱.۳.۱ حوزه فروش و درآمد

• ارزش کل فروش:

- تعریف محاسباتی: مجموع درآمد حاصل از تمامی سفارش‌های ثبت‌شده (حاصل ضرب قیمت در تعداد) پس از کسر تخفیف‌های اعمال‌شده.
- کاربرد مدیریتی: اصلی‌ترین معیار برای ارزیابی مقیاس، سنجش رشد کسب‌وکار و بررسی عملکرد کلی سیستم فروش.

• میانگین ارزش سفارش:

- تعریف محاسباتی: تقسیم ارزش کل فروش بر تعداد کل سفارش‌ها در یک بازه زمانی مشخص.
- کاربرد مدیریتی: ارزیابی میزان موفقیت استراتژی‌های فروش مکمل و بیش‌فروشی در سبد خرید مشتریان سازمانی.

• فروش و سودآوری منطقه‌ای:

- تعریف محاسباتی: جمع و تفکیک میزان فروش بر اساس موقعیت جغرافیایی ثبت‌شده برای مشتریان.
- کاربرد مدیریتی: شناسایی بازارهای هدف پربازده و تخصیص هوشمندانه بودجه برای توسعه شبکه فروش در مناطق جغرافیایی مستعد.

۲.۳.۱ حوزه عملیات و لجستیک

• نرخ تحویل به‌موقع:

- تعریف محاسباتی: نسبت تعداد سفارش‌هایی که پیش از تاریخ درخواستی مشتری ارسال شده‌اند به کل سفارش‌ها.
- کاربرد مدیریتی: سنجش میزان پایبندی به تعهدات زمانی و ارزیابی کیفیت خدمات ارائه‌شده توسط شرکت‌های حمل‌ونقل.

• متوسط زمان پردازش سفارش:

- تعریف محاسباتی: محاسبه میانگین فاصله زمانی (به روز) میان لحظه ثبت سفارش تا تحویل آن به واحد ارسال.

^۱ KPIs (Key Performance Indicators)

○ کاربرد مدیریتی: سنجش چابکی سازمان و کشف گلوگاه‌های احتمالی در فرآیند انبارداری و پردازش سفارش.

● نسبت هزینه حمل‌ونقل به ارزش سفارش:

- تعریف محاسباتی: محاسبه سهم هزینه حمل از کل درآمد هر سفارش.
- کاربرد مدیریتی: ارزیابی کارایی فرآیندهای لجستیکی و کنترل هزینه‌های سربار زنجیره تامین جهت حفظ حاشیه سود.

۳.۳.۱ حوزه مشتریان و کارکنان

● ارزش طول عمر مشتری:

- تعریف محاسباتی: مجموع ارزش خریدهای یک مشتری در کل بازه زمانی همکاری با مجموعه نورث‌ویند.
- کاربرد مدیریتی: شناسایی مشتریان کلیدی و اولویت‌بندی تخصیص منابع برای خدمات پس از فروش و برنامه‌های وفاداری.

● نرخ نگهداشت مشتری:

- تعریف محاسباتی: درصد مشتریانی که پس از ثبت اولین سفارش، حداقل یک سفارش دیگر نیز در سیستم ثبت کرده‌اند.
- کاربرد مدیریتی: ارزیابی میزان رضایت مشتریان از کیفیت محصولات و خدمات و موفقیت سازمان در حفظ روابط تجاری بلندمدت.

● بهره‌وری فروش کارکنان:

- تعریف محاسباتی: محاسبه حجم و ارزش کل فروش ایجادشده توسط هر یک از کارمندان به صورت مجزا.
- کاربرد مدیریتی: ارزیابی دقیق عملکرد فردی نیروی کار، طراحی سیستم‌های پاداش و کمیسیون عادلانه و بهینه‌سازی ساختار تیم فروش.

۲ فاز اول

۱.۲ پیش‌پردازش و پاک‌سازی داده‌ها

ابتدا مسیر فایل‌های داده و لیست تمامی جداول پروژه تعریف شد. سپس مجموعه‌ای از مقادیر متداول که ممکن است در فایل‌های متنی به جای مقدار گمشده استفاده شده باشند (مانند رشته خالی، فاصله، NA، NULL، علامت سؤال و ...) مشخص گردید تا هنگام خواندن فایل‌ها به عنوان مقدار گمشده شناسایی شوند. در ادامه، هر فایل CSV^۱ به صورت جداگانه بارگذاری شد. علاوه بر مقادیر استاندارد، سلول‌هایی که تنها شامل فاصله یا کاراکترهای سفید بودند نیز با استفاده از عبارت منظم^۲ به مقدار گمشده تبدیل شدند. پس از آماده‌سازی داده‌ها، برای هر ستون تعداد مقادیر گمشده، درصد مقادیر گمشده، درصد داده‌های موجود و نوع داده ستون محاسبه شد. در نهایت تمامی نتایج در یک چارچوب داده^۳ جمع شدند تا در مراحل بعد برای تحلیل، گزارش‌گیری و تصمیم‌گیری مورد استفاده قرار گیرند. پس از محاسبه درصد مقادیر گمشده، نتایج به صورت یک گزارش HTML تعاملی و خوانا نمایش داده شد. هدف از این گزارش، فراهم کردن نمایی جامع از وضعیت کیفیت داده‌ها در تمامی جدول‌های پایگاه داده و تسهیل فرآیند تصمیم‌گیری برای مراحل بعدی پاک‌سازی داده‌ها است.

پس از محاسبه درصد مقادیر گمشده، در این مرحله تنها ستون‌هایی که درصد داده‌های گمشده آن‌ها از آستانه تعیین‌شده (به‌صورت پیش‌فرض ۳۰ درصد) بیشتر است، استخراج و گزارش می‌شوند تا ستون‌های نیازمند تصمیم‌گیری شناسایی شوند.

Columns with >30% missing values:				
file	column	missing_count	missing_pct	
Categories.csv	Description	4	44.44	
Customers.csv	Region	61	65.59	
Customers.csv	Fax	31	33.33	
Employees.csv	Region	5	50.00	
Orders.csv	ShipRegion	511	61.20	
Products.csv	QuantityPerUnit	26	32.91	
Suppliers.csv	HomePage	28	87.50	
Suppliers.csv	Region	22	68.75	
Suppliers.csv	Fax	22	68.75	

شکل ۱: گزارش ستون‌های دارای بیش از ۳۰ درصد مقادیر گمشده در هر جدول

پس از شناسایی درصد مقادیر گمشده در تمامی ستون‌ها، ستون‌هایی که بیش از ۳۰ درصد داده گمشده داشتند به‌صورت جداگانه استخراج شدند تا مطابق الزامات پروژه، وضعیت آن‌ها به‌طور دقیق بررسی شود. برای این منظور، درصد مقادیر گمشده هر ستون محاسبه و تنها ستون‌هایی که از آستانه تعیین‌شده عبور کرده بودند در قالب یک گزارش مجزا نمایش داده شدند. این کار باعث شد تمرکز فرآیند پاک‌سازی بر ستون‌هایی قرار گیرد که بیشترین تأثیر را بر کیفیت داده‌ها دارند و نیازمند تصمیم‌گیری درباره حذف یا جایگزینی مقادیر هستند. در ادامه، برای رفع مقادیر گمشده موجود در ستون توضیحات^۴ جدول دسته‌بندی‌ها^۵، به‌جای استفاده از روش‌های عمومی مانند حذف داده یا جایگزینی با مقادیر ثابت، از توضیحات استاندارد

^۱Comma-Separated Values

^۲Regular Expression

^۳DataFrame

^۴Description

^۵Categories

ارائه شده در مستندات رسمی پایگاه داده نورث‌ویند استفاده شد. ابتدا نام دسته‌ها به‌منظور جلوگیری از خطاهای ناشی از فاصله‌های اضافی استانداردسازی گردید و سپس تنها ردیف‌هایی که مقدار توضیح آن‌ها خالی بود تکمیل شدند. با این رویکرد، اطلاعات معتبر حفظ شد، از بازنویسی داده‌های صحیح جلوگیری گردید و مقادیر گمشده بر اساس منطق کسب‌وکار و یک منبع معتبر جایگزین شدند.

```
1 official_docs_mapping = {'Beverages': 'Soft drinks, coffees, teas, beers, and ales',
2   'Condiments': 'Sweet and savory sauces, relishes, spreads, and seasonings',
3   'Confections': 'Desserts, candies, and sweet breads',
4   'Dairy Products': 'Cheeses',
5   'Grains/Cereals': 'Breads, crackers, pasta, and cereal',
6   'Meat/Poultry': 'Prepared meats',
7   'Produce': 'Dried fruit and bean curd',
8   'Seafood': 'Seaweed and fish'}
```

پس از شناسایی مقادیر گمشده، ستون‌های متنی جداول مشتریان، کارکنان، سفارش‌ها و تأمین‌کنندگان^۱ که اطلاعات توصیفی کاربران، کارکنان، سفارش‌ها و تأمین‌کنندگان را نگهداری می‌کنند، مورد بررسی قرار گرفتند. با توجه به ماهیت این ستون‌ها، حذف رکوردها یا استفاده از روش‌های آماری مانند میانگین و میانه برای جایگزینی مقادیر گمشده منطقی نبود؛ زیرا این روش‌ها تنها برای داده‌های عددی کاربرد دارند و می‌توانند موجب از بین رفتن اطلاعات یا ایجاد مقادیر نامعتبر شوند. به همین دلیل، بر اساس مفهوم هر ستون از مقادیر جایگزین معنادار استفاده شد؛ به‌طوری‌که مقدار Unknown برای ستون‌های Region و ShipRegion، مقدار No Fax برای ستون Fax و مقدار No Website برای ستون HomePage در نظر گرفته شد. این مقادیر نشان می‌دهند که اطلاعات مربوطه در منبع اولیه ثبت نشده است و با مقادیر واقعی اشتباه گرفته نخواهند شد.

به‌منظور اطمینان از صحت عملیات، تعداد مقادیر گمشده هر ستون قبل و بعد از جایگزینی محاسبه و مقایسه شد تا مشخص شود تمامی مقادیر هدف به‌درستی تکمیل شده‌اند. در پایان نیز فایل‌های اصلاح‌شده ذخیره شدند تا در مراحل بعدی پیش‌پردازش، تحلیل و انتقال داده‌ها به پایگاه داده مورد استفاده قرار گیرند. این رویکرد علاوه بر حفظ تمامی رکوردها، باعث افزایش کیفیت داده‌ها و جلوگیری از بروز خطا در تحلیل‌های بعدی می‌شود.

Suppliers Table Status (Before Cleaning):

- Region: 22 missing values
- Fax: 22 missing values
- HomePage: 28 missing values

Suppliers Table Status (After Cleaning):

- Region: 0 missing values
- Fax: 0 missing values
- HomePage: 0 missing values

Suppliers.csv cleaned and saved successfully!

Processing Customers.csv:

- Region: 61 -> 0 missing values
- Fax: 31 -> 0 missing values
- ✓ Customers.csv cleaned and saved successfully.

Processing Employees.csv:

- Region: 5 -> 0 missing values
- ✓ Employees.csv cleaned and saved successfully.

Processing Orders.csv:

- ShipRegion: 511 -> 0 missing values
- ✓ Orders.csv cleaned and saved successfully.

شکل ۳: گزارش پاک‌سازی ستون‌های متنی با جایگزینی مقادیر گمشده به‌صورت معنادار (مانند Unknown و No Fax)

شکل ۴: گزارش پاک‌سازی ستون‌های متنی با جایگزینی مقادیر گمشده به‌صورت معنادار (مانند Unknown و No Fax)

در جدول محصولات^۲ نیز ستون QuantityPerUnit دارای مقادیر گمشده بود. از آنجا که این ستون نحوه بسته‌بندی یا واحد عرضه هر محصول را توصیف می‌کند و یک ویژگی متنی محسوب می‌شود، جایگزینی

^۱Suppliers

^۲Products

آن با مقادیر آماری یا حذف رکوردها مناسب نبود. بنابراین، برای حفظ تمامی محصولات و مشخص بودن وضعیت اطلاعات ناقص، مقادیر گمشته این ستون با عبارت Not Specified جایگزین شد. این مقدار نشان می‌دهد که اطلاعات مربوط به نحوه بسته‌بندی محصول در داده‌های اولیه ثبت نشده است، بدون آنکه مفهوم نادرستی به داده اضافه شود.

```
Products Table Status (Before Cleaning):  
- QuantityPerUnit: 26 missing values  
-----  
Products Table Status (After Cleaning):  
- QuantityPerUnit: 0 missing values  
  
Products.csv cleaned and saved successfully!
```

شکل ۴: تعداد مقادیر گمشته قبل و بعد اصلاح

در مرحله بعد، عملیات استانداردسازی روی تمامی ستون‌های متنی انجام شد. این عملیات شامل حذف فاصله‌های اضافی ابتدا و انتهای متن، تبدیل چند فاصله متوالی به یک فاصله، یکسان‌سازی قالب نگارش متن و تبدیل رشته‌هایی مانند Nan، None و مقادیر خالی به مقدار استاندارد NA بود. با این حال، برخی ستون‌ها مانند شناسه‌ها (CustomerID و CustomerTypeID)، تاریخ‌ها، مسیر تصاویر (PhotoPath)، آدرس صفحات وب (HomePage) و داده‌های دودویی تصاویر از این فرآیند مستثنی شدند؛ زیرا تغییر قالب آن‌ها می‌توانست موجب از بین رفتن اطلاعات یا ایجاد ناسازگاری در داده‌ها شود. در پایان، نسخه استاندارد شده تمامی جداول ذخیره شد تا داده‌ها از نظر قالب نوشتاری یکدست، سازگار و آماده ورود به مراحل بعدی تحلیل و بارگذاری در پایگاه داده باشند.

```
1 def normalize_text(df):  
2     text_cols = df.select_dtypes(include=['object']).columns  
3     exclude_cols = ['Picture', 'Photo',  
4                     'CustomerID', 'CustomerTypeID',  
5                     'BirthDate', 'HireDate', 'OrderDate',  
6                     'RequiredDate', 'ShippedDate',  
7                     'HomePage', 'PhotoPath']  
8     for col in text_cols:  
9         if col in exclude_cols:  
10            continue  
11        df[col] = df[col].astype(str).str.strip()  
12        df[col] = df[col].str.replace(r'\s+', ' ', regex=True)  
13        df[col] = df[col].str.title()  
14        df[col] = df[col].replace({  
15            '': pd.NA,  
16            'Nan': pd.NA,  
17            'None': pd.NA,  
18            '<Na>': pd.NA})  
19    return df
```

یکی دیگر از مراحل پاک‌سازی داده‌ها، بررسی و حذف ردیف‌های کاملاً تکراری در تمامی جداول پایگاه داده بود. برای افزایش دقت این فرآیند، پیش از مقایسه رکوردها، داده‌های متنی در یک نسخه موقت استانداردسازی شدند؛ به‌طوری‌که تفاوت‌هایی مانند حروف بزرگ و کوچک یا فاصله‌های اضافی در ابتدا و

انتهای متن، باعث تشخیص نادرست رکوردهای یکسان نشوند. این استانداردسازی تنها برای فرآیند تشخیص تکراری بودن انجام شد و داده‌های اصلی در این مرحله تغییری نکردند.

در مقابل، برخی ستون‌ها مانند تصاویر، تاریخ‌ها و سایر داده‌هایی که تغییر قالب آن‌ها می‌توانست بر محتوای واقعی اطلاعات تأثیر بگذارد، از فرآیند استانداردسازی مستثنی شدند. پس از شناسایی، تنها نسخه‌های تکراری هر رکورد حذف و اولین نمونه آن حفظ شد. در پایان، تعداد رکوردهای حذف‌شده برای هر جدول گزارش و فایل‌های اصلاح‌شده ذخیره شدند. این فرآیند موجب کاهش افزونگی داده‌ها، حفظ یکپارچگی اطلاعات و جلوگیری از ایجاد خطا در تحلیل‌ها و محاسبات مراحل بعدی شد.

```
Starting duplicate row detection and removal...
=====
[REMOVED] Categories.csv: 1 duplicate row(s) removed.
[OK] CustomerCustomerDemo.csv: No duplicate rows found.
[OK] CustomerDemographics.csv: No duplicate rows found.
[REMOVED] Customers.csv: 2 duplicate row(s) removed.
[OK] Employees.csv: No duplicate rows found.
[REMOVED] EmployeeTerritories.csv: 3 duplicate row(s) removed.
[REMOVED] Order_Details.csv: 9 duplicate row(s) removed.
[OK] Orders.csv: No duplicate rows found.
[REMOVED] Products.csv: 1 duplicate row(s) removed.
[REMOVED] Region.csv: 1 duplicate row(s) removed.
[REMOVED] Shippers.csv: 1 duplicate row(s) removed.
[REMOVED] Suppliers.csv: 3 duplicate row(s) removed.
[REMOVED] Territories.csv: 4 duplicate row(s) removed.
=====
Duplicate removal completed successfully for all database tables.
```

شکل ۵: گزارش حذف ردیف‌های کاملاً تکراری از تمام جداول پایگاه داده

در ادامه فرآیند پاک‌سازی، جدول جزئیات سفارش‌ها^۱ از نظر صحت داده‌های مالی مورد بررسی قرار گرفت. با توجه به اینکه ستون‌های قیمت واحد^۲ و مقدار^۳ در محاسبه ارزش سفارش‌ها نقش مستقیم دارند، وجود مقادیر صفر یا منفی در این ستون‌ها می‌تواند منجر به ایجاد نتایج نادرست در تحلیل‌های مالی و گزارش‌های مدیریتی شود. به همین دلیل، تمامی رکوردهای جدول از نظر این دو معیار اعتبارسنجی شدند و تعداد ردیف‌های دارای مقادیر نامعتبر شناسایی و گزارش گردید. پس از تکمیل مرحله اعتبارسنجی، رکوردهایی که در آن‌ها مقدار UnitPrice یا Quantity کمتر یا مساوی صفر بود از مجموعه داده حذف شدند. دلیل انتخاب حذف این رکوردها آن بود که چنین مقادیری از دیدگاه منطق کسب‌وکار فاقد اعتبار هستند و امکان جایگزینی آن‌ها با روش‌های آماری یا مقادیر پیش‌فرض وجود ندارد؛ زیرا هر مقدار جایگزین می‌تواند باعث تحریف محاسبات مالی شود. پس از حذف رکوردهای نامعتبر، تعداد ردیف‌های حذف‌شده محاسبه و جدول اصلاح‌شده ذخیره گردید تا تنها داده‌های معتبر در مراحل بعدی تحلیل، محاسبه ارزش سفارش‌ها و ساخت داشبورد مورد استفاده قرار گیرند.

^۱Order_Details

^۲UnitPrice

^۳Quantity

Order_Details Data Validation Report					
=====					
Rows with zero or negative UnitPrice : 6					
Rows with zero or negative Quantity : 10					
=====					
Invalid records found:					
	OrderID	ProductID	UnitPrice	Quantity	Discount
87	10281	24	3.60	-6.0	0.00
127	10294	75	6.20	-6.0	0.00
164	10309	6	-20.00	30.0	0.00
221	10330	72	27.80	0.0	0.15
374	10389	10	24.80	-16.0	0.00
404	10399	77	-10.40	14.0	0.00
438	10412	14	18.60	0.0	0.10
641	10490	59	44.00	0.0	0.00
684	10510	29	0.00	36.0	0.00
1052	10647	39	18.00	0.0	0.00
1179	10697	19	-9.20	7.0	0.25
1189	10700	1	-18.00	5.0	0.20
1468	10810	25	0.00	5.0	0.00
1621	10865	39	18.00	-80.0	0.05
1737	10916	57	19.50	0.0	0.00
1980	11014	41	9.65	-28.0	0.10

شکل ۶: نمایش ردیف هایی با مقادیر صفر یا منفی برای تعداد یا قیمت کالا

در ادامه فرآیند پاک‌سازی داده‌ها، ستون‌های متنی جداول مشتریان، کارکنان و تأمین‌کنندگان به‌صورت دقیق‌تری بررسی شدند. علاوه بر مقادیر گمشده استاندارد (NaN)، رشته‌هایی مانند ”nan”، ”None“، ”” و رشته‌های خالی نیز به‌عنوان داده‌های ناقص شناسایی شدند؛ زیرا این مقادیر ممکن است در اثر ورود داده یا تبدیل فایل‌ها به‌صورت متن ذخیره شده باشند و در صورت عدم اصلاح، موجب ناسازگاری در تحلیل داده‌ها یا بارگذاری در پایگاه داده شوند. به همین دلیل، تمامی این نمایش‌های مختلف به‌عنوان یک نوع داده گمشده در نظر گرفته شدند تا فرآیند تکمیل داده‌ها به‌صورت یکنواخت و استاندارد انجام شود.

برای هر ستون، مقدار جایگزین متناسب با مفهوم آن انتخاب شد تا ضمن حفظ معنای اطلاعات، مشخص باشد که مقدار اولیه در داده‌های اصلی وجود نداشته است. به‌عنوان نمونه، در ستون‌های Region، ContactTitle، ContactName و City از مقدار Unknown، در ستون Fax از No Fax، در HomePage از No Website، در PhotoPath از No Path Available و در Notes از No Notes Available استفاده شد. همچنین در جدول کارکنان، ستون ReportsTo بر اساس ساختار سازمانی تکمیل شد؛ به‌طوری‌که مقدار 0 برای کارکنانی که سرپرست بالادستی نداشتند در نظر گرفته شد تا جایگاه مدیر ارشد سازمان^۱ مشخص باشد. علاوه بر این، ستون تصویر^۲ به دلیل نگهداری داده‌های باینری و نداشتن کاربرد در تحلیل داده‌ها، ساخت داشبوردهای پاور بی‌آی^۳ و طراحی پایگاه داده حذف گردید. پس از اعمال تمامی اصلاحات، فایل‌های به‌روزشده ذخیره و نتایج عملیات ثبت شدند تا مجموعه داده از نظر یکپارچگی، سازگاری و آمادگی برای مراحل بعدی پردازش در وضعیت مناسبی قرار گیرد.

^۱Top-Level Executive

^۲Photo

^۳Power BI

EMPLOYEES TABLE - DATA CLEANING & IMPUTATION

```
[OK] Photo      : Binary column removed
[OK] FirstName  : 1 value(s) replaced
[OK] TitleOfCourtesy : 2 value(s) replaced
[OK] PhotoPath  : 1 value(s) replaced
[OK] Notes      : 3 value(s) replaced
[OK] ReportsTo  : 1 value(s) replaced with 0
```

Total values imputed : 8

شکل ۷: پاکسازی و اصلاح کامل تمام مقادیر جدول کارمندان

در جدول Order_Details، ستون‌های عددی دارای مقدار گم‌شده با استفاده از یک رویکرد آماری بررسی و تکمیل شدند. ابتدا ستون تخفیف^۱ به دلیل ماهیت داده و منطق کسب‌وکار با مقدار 0.0 جایگزین شد؛ زیرا نبود مقدار تخفیف به این معناست که برای آن قلم سفارش تخفیفی اعمال نشده است. برای سایر ستون‌های عددی، شامل UnitPrice و Quantity، پیش از جایگزینی مقادیر گم‌شده، شاخص‌های آماری میانگین^۲، میانه^۳ و ضریب چولگی^۴ محاسبه شدند تا مناسب‌ترین روش تکمیل داده انتخاب شود. معیار تصمیم‌گیری بر اساس میزان چولگی توزیع داده‌ها بود. در صورتی که قدر مطلق ضریب چولگی از 1 بیشتر باشد، توزیع داده‌ها دارای چولگی قابل توجه در نظر گرفته شده و از میانه برای جایگزینی استفاده شد؛ زیرا این شاخص نسبت به مقادیر پرت مقاومت بیشتری دارد. در غیر این صورت، از میانگین استفاده شد، چرا که در توزیع‌های نسبتاً متقارن نماینده مناسبی برای مرکز داده‌ها محسوب می‌شود. پس از تکمیل مقادیر گم‌شده، ستون Quantity مجدداً به نوع داده عدد صحیح تبدیل شد تا با ماهیت شمارشی این متغیر سازگار باقی بماند. این رویکرد علاوه بر پاسخ‌گویی به الزامات پروژه مبنی بر مقایسه میانگین و میانه، انتخاب روش جایگزینی را بر اساس ویژگی‌های واقعی داده‌ها انجام می‌دهد و از اعمال یک روش ثابت برای تمامی متغیرها جلوگیری می‌کند.

ORDER_DETAILS TABLE - STATISTICAL IMPUTATION

[OK] Discount : 19 value(s) replaced with 0.0

Statistical Analysis : UnitPrice

```
Mean      : 28.78
Median    : 18.40
Skewness  : 13.06
Selected Method : Median (High Skewness)
Fill Value : 18.40
Missing Filled : 6
```

Statistical Analysis : Quantity

```
Mean      : 25.24
Median    : 20.00
Skewness  : 7.74
Selected Method : Median (High Skewness)
Fill Value : 20.00
Missing Filled : 15
```

Total values imputed : 40

شکل ۸: پر کردن ستون تخفیف و مقایسه میانه و میانگین و چولگی ستون‌های قیمت و تعداد

در این مرحله، ستون‌های OrderDate، RequiredDate و ShippedDate در جدول سفارش‌ها

^۱Discount

^۲Mean

^۳Median

^۴Skewness

به نوع داده زمان تاریخ^۱ تبدیل شدند تا امکان انجام پردازش‌های زمانی، محاسبات تاریخ و تحلیل‌های بعدی در محیط‌های SQL و Power BI فراهم شود. برای تبدیل تاریخ‌ها از تابع `to_datetime` با پارامتر `format='mixed'` استفاده شد تا قالب‌های مختلف تاریخ به‌درستی شناسایی شوند. همچنین با استفاده از `errors='coerce'`، مقادیر نامعتبر یا خالی بدون ایجاد خطا به مقدار نامعتبر زمانی^۲ تبدیل شدند. حفظ این مقادیر به‌صورت NaT اهمیت دارد؛ زیرا در جدول سفارش‌ها، خالی بودن ستون `ShippedDate` معمولاً نشان‌دهنده سفارش‌هایی است که هنوز ارسال نشده‌اند و این موضوع بخشی از منطق کسب‌وکار محسوب می‌شود، نه یک خطای داده.

```

1 for col in date_cols:
2     if col in df.columns:
3         df[col] = pd.to_datetime(
4             df[col],
5             format='mixed',
6             errors='coerce'
7         )
8     nat_count = int(df[col].isna().sum())
9     print(f"[OK] {col:<15}: Converted to datetime64[ns] | NaT = {nat_count}")
10 else:
11     print(f"[SKIP] {col:<15}: Column not found")

```

علاوه بر این، ستون کد پستی مقصد^۳ از نظر مقادیر گم‌شده بررسی شد و تمامی مقادیر خالی با مقدار `Unknown` جایگزین شدند تا نمایش داده‌های ناقص در این ستون به‌صورت یکنواخت استاندارد شود. در پایان، فایل اصلاح‌شده ذخیره شد تا ساختار داده‌ها از نظر نوع داده و یکپارچگی مقادیر برای مراحل بعدی پردازش، طراحی پایگاه داده و ساخت داشبورد آماده باشد.

```

1
2 if 'ShipPostalCode' in df.columns:
3     missing_postal = int(df['ShipPostalCode'].isna().sum())
4     df['ShipPostalCode'] = (
5         df['ShipPostalCode']
6         .fillna('Unknown')
7         .astype(str)
8         .str.strip()
9     )
10    print(f"[OK] ShipPostalCode : {missing_postal} value(s) replaced with 'Unknown'")

```

پس از اتمام تمامی مراحل پاک‌سازی و تکمیل داده‌ها، یک بررسی نهایی بر روی تمام جداول پایگاه داده انجام شد تا وضعیت مقادیر گم‌شده در مجموعه داده ارزیابی شود. در این مرحله، تعداد و درصد مقادیر گم‌شده برای تمامی ستون‌های هر جدول مجدداً محاسبه و گزارش شد. هدف از این بررسی، اطمینان از اثربخشی عملیات پاک‌سازی و شناسایی ستون‌هایی بود که ممکن است همچنان دارای داده‌های ناقص باشند. نتایج این ارزیابی به‌عنوان یک مرحله کنترل کیفیت^۴ مورد استفاده قرار گرفت و امکان مقایسه وضعیت داده‌ها قبل و بعد از عملیات پیش‌پردازش را فراهم کرد. انجام این بررسی نهایی باعث شد اطمینان حاصل شود که داده‌ها از نظر کامل بودن اطلاعات، سازگاری و آمادگی برای ورود به مراحل بعدی پروژه، از جمله طراحی پایگاه داده، تحلیل داده و ساخت داشبوردهای Power BI، در وضعیت مناسبی قرار دارند.

^۱ Datetime

^۲ NaT: Not a Time

^۳ ShipPostalCode

^۴ Quality Assurance

پس از اتمام عملیات پاک‌سازی داده‌ها، نوع داده تمامی ستون‌های موجود در جداول پایگاه داده مورد بررسی قرار گرفت تا از سازگاری آن‌ها با مفهوم واقعی داده و همچنین الزامات ورود به پایگاه داده‌های مایکروسافت اکسس^۱ و SQL Server اطمینان حاصل شود. در این مرحله، گزارشی از نوع داده هر ستون تهیه شد تا ستون‌هایی که نوع داده آن‌ها با ماهیت اطلاعات ذخیره‌شده مطابقت نداشت، شناسایی شوند. این بررسی نقش یک مرحله کنترل کیفیت را داشت و مبنای انجام اصلاحات لازم در ساختار داده‌ها قرار گرفت.

بر اساس نتایج این بررسی، نوع داده تعدادی از ستون‌ها استانداردسازی شد. ستون‌های OrderDate، HireDate و BirthDate در جدول سفارش‌ها و همچنین ستون‌های ShippedDate و RequiredDate در جدول کارکنان به نوع زمان‌تاریخ^۲ تبدیل شدند تا امکان انجام پردازش‌های زمانی، فیلترهای مبتنی بر تاریخ و تحلیل‌های زمانی در مراحل بعدی فراهم شود.

```
[TABLE] Orders
-----
[OK] OrderDate      -> datetime64[ns]
[OK] RequiredDate   -> datetime64[ns]
[OK] ShippedDate    -> datetime64[ns]
[SAVED] Orders.csv updated successfully.

[TABLE] Employees
-----
[OK] BirthDate      -> datetime64[ns]
[OK] HireDate       -> datetime64[ns]
[OK] Extension      -> String
[SAVED] Employees.csv updated successfully.

[TABLE] Territories
-----
[OK] TerritoryID    -> String (Length = 5)
[SAVED] Territories.csv updated successfully.

[TABLE] EmployeeTerritories
-----
[OK] TerritoryID    -> String (Length = 5)
[SAVED] EmployeeTerritories.csv updated successfully.
```

شکل ۹: استاندارد سازی ستون‌های ذکر شده

علاوه بر این، ستون افزونه^۳ در جدول کارکنان که ماهیتی شناسه‌ای و متنی دارد، از نوع عددی به رشته^۴ تبدیل شد تا صفرهای ابتدایی یا قالب اصلی آن حفظ شود. همچنین ستون TerritoryID در جداول Territories و EmployeeTerritories به رشته تبدیل و با استفاده از صفرهای ابتدایی تا طول پنج کاراکتر استانداردسازی شد. این کار باعث شد قالب کلید اصلی و کلید خارجی در هر دو جدول کاملاً یکسان باشد و از بروز ناسازگاری در برقراری ارتباط بین جداول جلوگیری شود. پس از اعمال تمامی اصلاحات، فایل‌های به‌روزشده ذخیره و مجدداً بررسی شدند تا اطمینان حاصل شود نوع داده تمامی ستون‌های اصلاح‌شده با ساختار منطقی پایگاه داده سازگار بوده و مجموعه داده برای استفاده در مراحل بعدی پروژه کاملاً آماده است.

در پایان مرحله استانداردسازی نوع داده‌ها، تمامی ستون‌های شناسه^۵ در جداول پایگاه داده از نظر صحت و یکپارچگی مورد بررسی قرار گرفتند. در این بررسی، تمام ستون‌هایی که نام آن‌ها با ID پایان می‌یافت شناسایی شدند و از دو جنبه مورد ارزیابی قرار گرفتند: وجود مقادیر گمشده (Null) و وجود مقادیر غیر عددی

^۱Microsoft Access

^۲Datetime

^۳Extension

^۴String

^۵ID

در ستون‌هایی که ماهیت عددی دارند. از آنجا که ستون‌های CustomerID و CustomerTypeID به صورت شناسه‌های متنی طراحی شده‌اند، این دو ستون از بررسی مقادیر غیر عددی مستثنی شدند. برای سایر ستون‌های شناسه، با تبدیل آزمایشی مقادیر به نوع عددی، هرگونه مقدار نامعتبر یا غیرقابل تبدیل شناسایی شد. نتایج این بررسی برای هر جدول به صورت جداگانه گزارش گردید تا در صورت وجود هرگونه ناهماهنگی، امکان اصلاح آن فراهم باشد.

۲.۲ مهندسی ویژگی‌ها و آماده‌سازی جهت تحلیل

در این مرحله، به منظور افزایش قابلیت تحلیل داده‌ها و آماده‌سازی مجموعه داده برای طراحی داشبوردهای Power BI، چندین ویژگی جدید از اطلاعات موجود در جدول سفارش‌ها استخراج شد. ابتدا ستون‌های زمانی به نوع داده استاندارد تبدیل شدند تا انجام محاسبات زمانی امکان‌پذیر باشد. سپس از تاریخ سفارش، ویژگی‌های سال سفارش^۱، ماه سفارش^۲ و روز هفته^۳ استخراج شدند. این ویژگی‌ها امکان تحلیل روند سفارش‌ها در بازه‌های زمانی مختلف، مقایسه عملکرد ماهانه و بررسی الگوهای ثبت سفارش در روزهای مختلف هفته را فراهم می‌کنند.

علاوه بر ویژگی‌های زمانی، دو ویژگی جدید نیز با هدف تحلیل عملکرد فرایند ارسال سفارش‌ها ایجاد شد. ویژگی مدت زمان ارسال^۴ مدت‌زمان بین ثبت سفارش و ارسال آن را بر حسب روز محاسبه می‌کند و می‌تواند برای ارزیابی سرعت ارسال کالا مورد استفاده قرار گیرد. همچنین ویژگی وضعیت تحویل^۵ با مقایسه تاریخ ارسال واقعی و تاریخ مورد انتظار وضعیت هر سفارش را در دو دسته به موقع^۶ و دارای تأخیر^۷ طبقه‌بندی می‌کند. این ویژگی یک شاخص کاربردی برای ارزیابی عملکرد فرایند لجستیک و تحلیل میزان تأخیر در تحویل سفارش‌ها محسوب می‌شود و می‌تواند در گزارش‌ها و داشبوردهای مدیریتی به عنوان یکی از شاخص‌های کلیدی عملکرد مورد استفاده قرار گیرد.

FEATURE ENGINEERING - ORDERS TABLE								
Generated Features Preview								
OrderID	OrderDate	RequiredDate	ShippedDate	OrderYear	OrderMonth	OrderDayOfWeek	ShippingDurationDays	Delivery_Status
10248	1996-04-07	1996-08-01	1996-07-16	1996	4	Sunday	100.0	On-Time
10249	1996-07-05	1996-08-16	1996-07-10	1996	7	Friday	5.0	On-Time
10250	1996-07-08	1996-05-08	1996-07-12	1996	7	Monday	4.0	Delayed
10251	1996-08-07	1996-08-05	1996-07-15	1996	8	Wednesday	-23.0	On-Time
10252	1996-07-09	1996-06-08	1996-07-11	1996	7	Tuesday	2.0	Delayed
Delayed Orders : 89								
On-Time Orders : 746								
STATUS : FEATURE ENGINEERING COMPLETED SUCCESSFULLY								

شکل ۱۰: اضافه کردن ۵ ستون جدید برای تحلیل راحت‌تر اطلاعات و طراحی داشبور

در این بخش، ویژگی ارزش سفارش^۸ برای هر ردیف از جدول جزئیات سفارش‌ها بر اساس فرمول زیر

^۱OrderYear

^۲OrderMonth

^۳OrderDayOfWeek

^۴ShippingDurationDays

^۵Delivery_Status

^۶On-Time

^۷Delayed

^۸OrderValue

محاسبه و به مجموعه داده اضافه شد: $OrderValue = UnitPrice * Quantity * (1 - Discount)$ این ویژگی ارزش واقعی هر قلم سفارش را پس از اعمال تخفیف نشان می‌دهد و یکی از شاخص‌های اصلی در تحلیل فروش و محاسبه درآمد محسوب می‌شود. همچنین به منظور هم‌مقیاس‌سازی متغیرهای عددی، ستون‌های قیمت واحد و مقدار با استفاده از روش مقیاس‌بندی کمینه-بیشینه^۱ نرمال‌سازی شدند. در این روش، مقادیر هر ستون به بازه 0 تا 1 تبدیل شدند تا اختلاف مقیاس متغیرها کاهش یابد و امکان مقایسه و تحلیل آن‌ها در مراحل بعدی فراهم شود.

```

1 df_od['OrderValue'] = (
2 df_od['UnitPrice'] *
3 df_od['Quantity'] *
4 (1 - df_od['Discount']))
5 )
6 print(" [] Feature Created : OrderValue")
7
8 min_u = df_od['UnitPrice'].min()
9 max_u = df_od['UnitPrice'].max()
10 df_od['UnitPrice_Scaled'] = (
11 (df_od['UnitPrice'] - min_u) /
12 (max_u - min_u)
13 )
14 print(" [] UnitPrice scaled using Min-Max normalization.")
15
16 min_q = df_od['Quantity'].min()
17 max_q = df_od['Quantity'].max()
18 df_od['Quantity_Scaled'] = (
19 (df_od['Quantity'] - min_q) /
20 (max_q - min_q)
21 )

```

در بخش بعد، با ترکیب اطلاعات جداول سفارش‌ها و جزئیات سفارش‌ها، یک جدول جدید با نام ویژگی‌های مشتری^۲ ایجاد شد که نمایی تجمیع‌شده از رفتار خرید هر مشتری ارائه می‌دهد. برای هر مشتری، تعداد کل سفارش‌ها^۳، مجموع هزینه‌کرد^۴ و میانگین ارزش سفارش^۵ محاسبه شد تا شاخص‌های اصلی عملکرد مشتری در یک جدول مستقل در دسترس باشند.

به‌عنوان یک ویژگی تکمیلی، شاخص تازگی خرید^۶ نیز محاسبه شد که تعداد روزهای سپری‌شده از آخرین خرید هر مشتری را نسبت به آخرین تاریخ ثبت‌شده در مجموعه داده نشان می‌دهد. این شاخص در کنار تعداد سفارش‌ها و میزان هزینه‌کرد، سه مؤلفه اصلی تحلیل تازگی، تکرار و ارزش پولی^۷ را تشکیل می‌دهد و می‌تواند برای تحلیل رفتار مشتریان، بخش‌بندی آن‌ها و طراحی داشبوردهای مدیریتی مورد استفاده قرار گیرد. در پایان، جدول تولیدشده به‌صورت یک فایل مستقل ذخیره شد تا در مراحل بعدی پروژه قابل استفاده باشد.

^۱Min-Max Scaling

^۲Customer_Features

^۳Total_Orders

^۴Total_Spend

^۵Avg_Order_Value

^۶Recency_Days

^۷RFM Analysis

```

FEATURE ENGINEERING - CUSTOMER FEATURES TABLE
=====
Generated Customer Features
-----
CustomerID  Total_Orders  Total_Spend  Avg_Order_Value  Recency_Days
-----
ALFKI       6             4281.64      356.80           10129
ANATR       4             1402.95      140.30           10165
ANTON       7             7023.98      413.18           10200
AROUT       13            13390.65     446.35           10128
BERGS       18            27149.98     502.78           10075
-----
Customers Processed : 90
Features Created    : 5
=====
STATUS : CUSTOMER FEATURES TABLE CREATED SUCCESSFULLY
=====

```

شکل ۱۱: ساخت جدول ویژگی های مشتری

ویژگی جدید دسته بندی قیمت^۱ برای محصولات ایجاد شد تا کالاها بر اساس قیمت واحد در سه گروه ارزان^۲، متوسط^۳ و گران^۴ دسته بندی شوند. برای این منظور از روش گروه بندی مبتنی بر چندک^۵ استفاده شد که با تقسیم داده ها بر اساس چارک های آماری، تعداد محصولات را تا حد امکان به صورت متوازن میان سه گروه توزیع می کند. استفاده از این روش باعث می شود دسته بندی محصولات به توزیع واقعی قیمت ها وابسته باشد و تحت تأثیر انتخاب آستانه های دلخواه قرار نگیرد. ویژگی ایجاد شده می تواند در تحلیل ترکیب سبد محصولات، بررسی الگوی فروش محصولات ارزان و گران قیمت و طراحی داشبوردهای مدیریتی مورد استفاده قرار گیرد.

```

Price Category Ranges
-----
Low    : (2.499, 16.75]
Medium : (16.75, 31.077]
High   : (31.077, 583.0]

Generated Features Preview
-----
ProductID  ProductName  UnitPrice  PriceCategory
-----
1           Chai      18.00      Medium
2           Chang      19.00      Medium
3           Aniseed Syrup  10.00      Low
4 Chef Anton's Cajun Seasoning  22.00      Medium
5 Chef Anton's Gumbo Mix      576.45      High
6 Grandma's Boysenberry Spread  25.00      Medium
-----
STATUS : PRODUCT PRICE CATEGORIZATION COMPLETED
=====

```

شکل ۱۲: ایجاد ستون دسته بندی قیمت ها

در این بخش، تأثیر نرمال سازی با روش مقیاس بندی کمینه-بیشینه بر توزیع داده های ستون قیمت واحد بررسی شد. برای این منظور، دو شاخص آماری چولگی و کشیدگی^۶ قبل و بعد از نرمال سازی محاسبه

^۱PriceCategory

^۲Low

^۳Medium

^۴High

^۵Quantile-Based Binning

^۶Kurtosis

و با یکدیگر مقایسه شدند تا مشخص شود آیا شکل توزیع داده‌ها دچار تغییر شده است یا خیر. نتایج نشان داد که مقادیر این دو شاخص آماری پس از اعمال نرمال‌سازی تغییری نداشتند. این موضوع نشان می‌دهد که مقیاس‌بندی کمینه-بیشینه تنها مقیاس داده‌ها را به بازه 0 تا 1 منتقل می‌کند و به دلیل ماهیت خطی خود، شکل توزیع داده‌ها را حفظ می‌کند. بنابراین، استفاده از این روش باعث استانداردسازی مقیاس متغیرها بدون تغییر ویژگی‌های آماری اصلی آن‌ها می‌شود.

```
=====
NORMALIZATION EFFECT ANALYSIS
=====
Original UnitPrice
Skewness : 13.0796
Kurtosis : 232.0124
-----
Scaled UnitPrice
Skewness : 13.0796
Kurtosis : 232.0124
-----
Result : Distribution shape was preserved after Min-Max Scaling.
Skewness and kurtosis remained unchanged.
=====
```

شکل ۱۳: مقایسه نرمال‌سازی داده‌ها بر چولگی و کشیدگی داده‌ها

۳.۲ شناسایی و مدیریت داده‌های پرت

در بخش ابتدایی، هدف اصلی شناسایی و مدیریت داده‌های پرت و غیرمنطقی در جداول مختلف پایگاه داده نورشویند است تا کیفیت داده‌ها برای تحلیل‌های بعدی افزایش یابد. ابتدا همه فایل‌های موردنیاز شامل سفارش‌ها، جزئیات سفارش^۱، محصولات^۲، تأمین‌کنندگان، دسته‌بندی‌ها و ویژگی‌های مشتریان^۳ در قالب یک دیکشنری بارگذاری می‌شوند تا دسترسی به آن‌ها ساده‌تر باشد. سپس مقادیر نامعتبر تخفیف^۴ در جدول جزئیات سفارش که خارج از بازه منطقی صفر تا یک هستند، به مقدار گم‌شده^۵ تبدیل می‌شوند. در جدول سفارش‌ها، هزینه حمل^۶ منفی با قدرمطلق‌گیری اصلاح می‌شود، زیرا هزینه حمل نمی‌تواند مقدار منفی داشته باشد. همچنین در جدول محصولات، مقادیر منفی مربوط به موجودی کالا^۷، تعداد سفارش‌داده‌شده^۸ و سطح سفارش مجدد^۹ به صفر تبدیل می‌شوند، چون این مقادیر از نظر عملیاتی نباید منفی باشند. در جدول ویژگی‌های مشتریان نیز تعداد سفارش‌ها^{۱۰} و مجموع خرید یا هزینه کل مشتری^{۱۱} اگر صفر یا منفی باشند، به عنوان داده نامعتبر شناسایی و با مقدار گم‌شده جایگزین می‌شوند. در پایان، کد با تعریف چند بررسی کنترلی^{۱۲} اطمینان می‌دهد که خطاهای منطقی باقی نمانده‌اند و در صورت پاک بودن داده‌ها، وضعیت

¹Order_Details

²Products

³Customer_Features

⁴Discount

⁵NA

⁶Freight

⁷UnitsInStock

⁸UnitsOnOrder

⁹ReorderLevel

¹⁰Total_Orders

¹¹Total_Spend


¹²checks

پاک بودن داده‌ها^۱ گزارش می‌شود.

```
Negative Freight      0
Invalid Discount      0
Negative UnitsInStock 0
Negative UnitsOnOrder 0
Negative ReorderLevel 0
Invalid TotalOrders   0
Invalid TotalSpending 0
dtype: int64
Status : Clean
```

شکل ۱۴: آغاز مرحله پاکسازی داده

در ادامه، داده‌های پرت برای سه ستون قیمت واحد^۲، تعداد سفارش^۳ و هزینه حمل بررسی می‌شوند. برای هر ستون، ابتدا مقادیر گم‌شده حذف شده و سپس با استفاده از روش فاصله بین چارکی^۴، حدود پایین و بالای قابل قبول محاسبه می‌شود. مقادیری که خارج از این محدوده قرار بگیرند، به‌عنوان داده پرت^۵ شناسایی و تعداد آن‌ها در خروجی چاپ می‌شود. در نهایت، برای هر ستون یک نمودار جعبه‌ای^۶ رسم می‌شود تا پراکندگی داده‌ها و نقاط پرت به‌صورت بصری قابل مشاهده و مقایسه باشد.



شکل ۱۵: نمودار جعبه‌ای

برای مقایسه شناسایی داده‌های پرت^۷، دو روش فاصله بین چارکی^۸ و امتیاز استاندارد^۹ در نظر گرفته شده است. در این بررسی، ستون‌های عددی مهم از جداول جزئیات سفارش، سفارش‌ها، محصولات و ویژگی‌های مشتریان انتخاب می‌شوند. ابتدا داده‌ها به قالب عددی تبدیل شده و مقادیر نامعتبر یا گم‌شده حذف می‌شوند تا نتایج قابل اعتمادتر باشند. سپس در روش فاصله بین چارکی^{۱۰}، مقادیر خارج از محدوده چارک اول و سوم به‌عنوان داده پرت شناسایی می‌شوند. در روش امتیاز استاندارد^{۱۱} نیز مقادیری که

^۱Status: Clean

^۲UnitPrice

^۳Quantity

^۴IQR

^۵Outlier

^۶Boxplot

^۷Outliers

^۸IQR

^۹Z-Score

^{۱۰}IQR

^{۱۱}Z-Score

بیش از سه انحراف معیار از میانگین فاصله دارند، پرت محسوب می‌شوند. در نهایت، تعداد داده‌های پرت شناسایی شده با هر دو روش در قالب یک جدول مقایسه‌ای نمایش داده می‌شود تا تفاوت حساسیت این دو رویکرد در ستون‌های مختلف مشخص شود.

```


--- 4. Outliers Comparison (IQR vs Z-Score) ---

```

Table	Column	IQR_Outliers	Z-Score_Outliers
Order_Details	UnitPrice	105	32
Order_Details	Quantity	93	19
Order_Details	Discount	0	0
Orders	Freight	68	8
Products	UnitsInStock	0	0
Products	UnitsOnOrder	16	2
Products	ReorderLevel	0	0
Customer_Features	Total_Orders	3	3
Customer_Features	Total_Spend	7	4

شکل ۱۶: مقایسه داده‌های پرت از دو روش دامنه بین‌چارکی و امتیاز استاندارد

برای اجرای روش وینزوریزه کردن^۱، ستون هزینه حمل از جدول سفارش‌ها انتخاب شده است. در این روش، به‌جای حذف داده‌های پرت، مقادیر بسیار کوچک و بسیار بزرگ در یک بازه مشخص محدود می‌شوند. حد پایین و حد بالا بر اساس صدک‌های ۵ و ۹۵ درصد محاسبه شده و مقادیر خارج از این محدوده با نزدیک‌ترین مقدار مجاز جایگزین می‌شوند. این کار باعث کاهش اثر مقادیر افراطی بر نتایج تحلیل می‌شود، در حالی که ساختار کلی داده‌ها و تعداد رکوردها حفظ می‌گردد. در پایان، توزیع هزینه حمل قبل و بعد از وینزوریزه کردن با هیستوگرام مقایسه می‌شود تا تغییرات ایجادشده به‌صورت بصری قابل مشاهده باشد.



شکل ۱۷: مقایسه وضعیت داده‌های ستون Freight قبل و بعد از وینزوریزه کردن

برای بررسی وجود سفارش‌هایی با تعداد بسیار زیاد، ستون تعداد سفارش در جدول جزئیات سفارش تحلیل می‌شود. در این بررسی، ابتدا حدود نرمال داده‌ها با استفاده از روش فاصله بین‌چارکی محاسبه شده و سپس سفارش‌هایی که مقدار تعداد آن‌ها از حد بالای نرمال بیشتر باشد، به‌عنوان سفارش‌های غیرعادی شناسایی می‌شوند. علاوه بر شمارش این موارد، ده مقدار بزرگ‌تر ستون تعداد نیز نمایش داده می‌شود تا شدت مقادیر بالا بهتر قابل بررسی باشد. نمودار جعبه‌ای^۲ نیز برای مشاهده دیداری پراکندگی داده‌ها و تشخیص نقاط پرت استفاده می‌شود.

^۱Winsorizing

^۲Boxplot

برای بررسی قیمت‌های غیرعادی محصولات، ستون قیمت واحد در جدول محصولات مورد ارزیابی قرار می‌گیرد. در این بخش، حد پایین و حد بالا بر اساس روش فاصله بین چارکی تعیین می‌شود و محصولاتی که قیمت آن‌ها کمتر یا بیشتر از این بازه باشد، به عنوان قیمت غیرعادی پایین یا بالا شناسایی می‌شوند. سپس تعداد موارد غیرعادی گزارش شده و ده قیمت بالاتر و ده قیمت پایین‌تر محصولات نمایش داده می‌شود. در پایان، نمودار جعبه‌ای قیمت محصولات رسم می‌شود تا وجود قیمت‌های پرت و الگوی توزیع قیمت‌ها به صورت بصری قابل مشاهده باشد.

```
Limit: 60.0
High quantity orders: 93
Yes, high-quantity orders exist.

Top 10 highest Quantity values:
75      497
1754    433
1509    426
378     353
1477    340
1402    338
2139    328
523     310
1171    299
2104    130
```

شکل ۱۹: مقادیر بسیار بالا برای تعداد

```
Lower limit: -18.550000000000004
Upper limit: 68.25
Low-price outliers: 0
High-price outliers: 8
Yes, products with abnormal prices exist.

Top 10 highest product prices:
57      583.00
4        576.45
61       353.00
37       263.50
12       240.00
28       123.79
8         97.00
19       81.00
17       62.50
58       55.00

Top 10 lowest product prices:
32       2.50
23       4.50
51       7.00
53       7.45
74       7.75
22       9.00
18       9.20
46       9.50
44       9.50
40       9.65
```

شکل ۱۸: قیمت‌های بسیار پایین یا بالا

در این بخش، اثر حذف داده‌های پرت بر شاخص‌های آماری اصلی مانند میانگین و انحراف معیار^۱ بررسی می‌شود. ابتدا ستون‌های عددی مهم از جداول جزئیات سفارش، سفارش‌ها، محصولات و ویژگی‌های مشتریان انتخاب می‌شوند و داده‌های آن‌ها به قالب عددی تبدیل می‌گردند. سپس برای هر ستون، داده‌های پرت با استفاده از روش فاصله بین چارکی شناسایی و از مجموعه داده کنار گذاشته می‌شوند. پس از حذف مقادیر پرت، میانگین و انحراف معیار قبل و بعد از حذف محاسبه و با یکدیگر مقایسه می‌شوند. در پایان، میزان تغییر میانگین، تغییر انحراف معیار و تعداد داده‌های حذف‌شده در قالب یک جدول خلاصه نمایش داده می‌شود تا مشخص شود داده‌های پرت چه اثری بر توزیع و پراکندگی داده‌ها داشته‌اند.

	Table	Column	Mean Before	Std Before	Mean After	\
0	Order_Details	UnitPrice	28.755201	55.247172	21.314565	
1	Order_Details	Quantity	25.198598	29.537930	21.283341	
2	Order_Details	Discount	0.055645	0.083196	0.055645	
3	Orders	Freight	72.147612	82.839342	52.688050	
4	Products	UnitsInStock	39.487179	36.643861	39.487179	
5	Products	UnitsOnOrder	9.871795	23.046739	0.000000	
6	Products	ReorderLevel	12.435897	10.863486	12.435897	
7	Customer_Features	Total_Orders	9.200000	5.781023	8.505747	
8	Customer_Features	Total_Spend	17260.301889	25127.658545	11215.632771	
		Std After	Change in Mean	Change in Std	Removed Outliers	
0		12.869807	-7.440636	-42.377365	105	
1		14.283912	-3.915257	-15.254018	93	
2		0.083196	0.000000	0.000000	0	
3		52.238071	-19.459562	-30.601272	68	
4		36.643861	0.000000	0.000000	0	
5		0.000000	-9.871795	-23.046739	16	
6		10.863486	0.000000	0.000000	0	
7		4.461394	-0.694253	-1.319629	3	
8		10262.029271	-6044.669118	-14865.629273	7	

شکل ۲۰: تغییرات انحراف معیار و میانگین بعد حذف داده پرت

¹ Standard Deviation

منطق مدیریت داده‌های پرت^۱ بر پایه این فرض شکل گرفت که همه مقادیر پرت الزاماً خطا نیستند و نباید صرفاً به دلیل فاصله داشتن از الگوی عمومی داده‌ها حذف شوند. در داده‌های فروش، بسیاری از مقادیر بزرگ یا غیرمعمول می‌توانند بازتاب رخداد‌های واقعی کسب‌وکار باشند؛ برای مثال، سفارش‌هایی با تعداد بالا، هزینه حمل زیاد، یا مشتریانی با مجموع خرید چشمگیر، ممکن است دقیقاً همان موارد مهم و ارزشمندی باشند که شناخت آن‌ها برای تحلیل رفتار بازار ضروری است. به همین دلیل، میان «خطاهای فنی»^۲ و «پرت‌های تجاری»^۳ تمایز در نظر گرفته شد.

خطاهای فنی شامل مقادیری هستند که از نظر منطقی یا ساختاری نامعتبرند؛ مانند تخفیف خارج از بازه مجاز، مقادیر منفی در متغیرهایی که نباید منفی باشند، یا ثبت‌های ناسازگار با قواعد داده. این موارد چون بیانگر واقعیت نیستند، در مرحله پاک‌سازی اصلاح یا حذف شدند. اما مقادیری که فقط از نظر آماری در نواحی دورافتاده توزیع قرار دارند، لزوماً نامعتبر تلقی نشدند. برای این دسته، تصمیم بر حفظ رکورد و اضافه کردن یک شاخص کمکی اتخاذ شد تا وضعیت پرت بودن آن‌ها مشخص بماند، بدون آن‌که اطلاعات اصلی از بین برود.

برای این منظور، پس از محاسبه حدود نرمال هر متغیر با روش فاصله بین چارکی، رکوردهای خارج از این محدوده شناسایی شدند و برای هر ستون منتخب، یک متغیر بولی^۴ با عنوان IsOutlier ساخته شد. این علامت‌گذاری باعث می‌شود هر مشاهده پرت به صورت شفاف مستند شود، در حالی که خود داده همچنان در مجموعه اصلی باقی بماند. بنابراین، تصمیم نهایی درباره استفاده یا عدم استفاده از این رکوردها به مرحله تحلیل منتقل می‌شود، نه این‌که در همان مرحله پاک‌سازی به طور برگشت‌ناپذیر حذف شوند.

دلیل پرهیز از حذف آن است که حذف داده‌های پرت در داده‌های تجاری می‌تواند موجب از دست رفتن سیگنال‌های کلیدی و ایجاد سوگیری در نتایج شود. اگر سفارش‌های بزرگ، محصولات با قیمت‌های خاص، یا مشتریان با خرید بالا حذف شوند، تصویری که از واقعیت بازار به دست می‌آید، دیگر تصویر کاملی نخواهد بود. در چنین شرایطی، میانگین‌ها و شاخص‌های آماری ممکن است ظاهراً متعادل‌تر شوند، اما این تعادل به بهای حذف بخش مهمی از واقعیت عملیاتی سیستم حاصل می‌شود. از منظر تحلیلی، چنین کاری می‌تواند شناخت مشتریان ارزشمند، الگوهای خرید غیرمعمول و فرصت‌های بالقوه کسب‌وکار را محدود کند.

رویکرد نگهداری همراه با علامت‌گذاری این مزیت را ایجاد می‌کند که در ادامه، هم تحلیل بر مبنای داده‌های عادی ممکن باشد و هم بررسی مستقل روی رکوردهای پرت انجام شود. به بیان دیگر، داده‌های پرت به جای آن‌که به عنوان «مزاحم» کنار گذاشته شوند، به عنوان یک لایه اطلاعاتی مهم حفظ می‌شوند. این کار به تحلیل‌گر اجازه می‌دهد بسته به هدف مطالعه، یا آن‌ها را موقتاً از تحلیل‌های عمومی کنار بگذارد، یا برعکس، به صورت ویژه روی آن‌ها تمرکز کند. در نتیجه، فرآیند پاک‌سازی نه تنها به کاهش خطا کمک می‌کند، بلکه ظرفیت تحلیلی داده را نیز افزایش می‌دهد. در مجموع، تصمیم نهایی بر حذف نکردن داده‌های پرت، یک انتخاب صرفاً آماری نبود، بلکه انتخابی مبتنی بر منطق مسئله، ماهیت داده‌های فروش و ارزش اطلاعاتی رکوردهای غیرعادی بود. چنین تصمیمی نشان می‌دهد که مدیریت داده‌های پرت زمانی مؤثرتر است که به جای حذف شتاب‌زده، بر تشخیص، مستندسازی و استفاده هوشمندانه از آن‌ها تکیه شود.

۴.۲ اعتبارسنجی داده‌ها

در ابتدای بخش ششم، توالی منطقی تاریخ‌های مربوط به سفارش‌ها بررسی شد تا ناسازگاری‌های زمانی در جدول Orders شناسایی شوند. ابتدا ستون‌های OrderDate، RequiredDate و ShippedDate به قالب تاریخ تبدیل شدند و مقادیر نامعتبر به صورت NaT در نظر گرفته شدند. سپس کد بررسی کرد

^۱ Outlier Management

^۲ Technical Errors

^۳ Business Outliers

^۴ Boolean Flag

که تاریخ ارسال قبل از تاریخ سفارش نباشد، چون چنین حالتی از نظر فرآیند واقعی سفارش نامعتبر است. همچنین تاریخ موردنیاز نباید زودتر از تاریخ ثبت سفارش باشد، بنابراین این موارد نیز به عنوان خطای منطقی شناسایی شدند. برای حفظ سایر اطلاعات مفید سفارش، رکوردها حذف نشدند و فقط مقدارهای تاریخی اشتباه با NaT جایگزین شدند. در ادامه، سفارش‌هایی که بعد از تاریخ موردنیاز ارسال شده بودند با ستون Late_Shipment علامت‌گذاری شدند. در نهایت، تعداد روزهای تأخیر در ستون Delay_Days محاسبه شد تا این اطلاعات برای تحلیل عملکرد ارسال‌ها قابل استفاده باشد.

در ابتدا، ستون‌های تاریخ سفارش^۱، تاریخ موردنیاز^۲ و تاریخ ارسال^۳ به فرمت استاندارد زمانی^۴ تبدیل شدند تا امکان مقایسه ریاضی فراهم گردد. در مرحله بعد، سه سناریوی متناقض شامل پیشی گرفتن تاریخ ارسال بر سفارش، پیشی گرفتن تاریخ موردنیاز بر سفارش، و تأخیر ارسال نسبت به تاریخ درخواستی مشتری مورد سنجش قرار گرفتند. برای مدیریت خطاها، تصمیم بر آن شد که در صورت رخ دادن هرگونه تناقض زمانی، مقدار نامعتبر به عنوان داده‌ی مفقود ساختاریافته^۵ در نظر گرفته شود. این استراتژی پاک‌سازی تضمین می‌کند که رکوردهای ناسازگار از محاسبات زنجیره تأمین حذف شده و تحلیل‌های لجستیکی و زمان انتظار^۶ در مراحل بعدی دچار انحراف محاسباتی نشوند.

```
Date cleaning completed.
ShippedDate earlier than OrderDate fixed: 59
RequiredDate earlier than OrderDate fixed: 55
Late shipments detected: 60
```

شکل ۲۱: پاک‌سازی تاریخ‌های نامعتبر و غیرمنطقی

سپس، هدف حفظ یکپارچگی ارجاعی^۷ میان جدول جزئیات سفارش^۸ و جدول سفارش‌ها^۹ است؛ یعنی هر شناسه سفارش^{۱۰} که در جدول جزئیات سفارش ثبت شده، باید در جدول اصلی سفارش‌ها نیز وجود داشته باشد. برای این منظور، ابتدا شناسه‌های سفارش از هر دو جدول استخراج و با یکدیگر مقایسه شدند. سپس شناسه‌هایی که در جدول جزئیات سفارش وجود داشتند اما در جدول سفارش‌ها یافت نشدند، به عنوان رکوردهای نامعتبر شناسایی شدند. در مرحله پاک‌سازی، فقط ردیف‌هایی از جدول جزئیات سفارش نگه داشته شدند که شناسه سفارش آن‌ها در جدول سفارش‌ها موجود بود و سایر موارد حذف شدند. همچنین تعداد ردیف‌ها پیش و پس از اصلاح محاسبه شد تا میزان داده‌های حذف‌شده مشخص باشد. اجرای این فرایند باعث می‌شود رابطه میان جدول سفارش‌ها و جزئیات آن‌ها معتبر، سازگار و قابل اتکا باقی بماند و تحلیل‌های بعدی بر پایه داده‌های صحیح انجام شوند.

¹ OrderDate

² RequiredDate

³ ShippedDate

⁴ datetime

⁵ pd.NaT

⁶ Lead Time

⁷ Referential Integrity

⁸ Order_Details

⁹ Orders

¹⁰ OrderID


```
Referential integrity cleaning completed.  
Removed rows from Order_Details: 2  
Remaining rows in Order_Details: 2138
```

شکل ۲۲: بررسی و پاکسازی شناسه‌های بی‌پشتوانه

در ادامه، هدف شناسایی مقدارهای نامعتبر منطقی در ستون‌هایی است که طبق قواعد کسب‌وکار نباید منفی یا خارج از محدوده مجاز باشند. در جدول جزئیات سفارش بررسی می‌شود که تعداد سفارش بزرگ‌تر از صفر باشد، تخفیف در بازه مجاز صفر تا یک قرار بگیرد و قیمت واحد مقدار منفی نداشته باشد. همچنین در جدول سفارش‌ها هزینه حمل از نظر منفی نبودن کنترل می‌شود. در جدول محصولات نیز موجودی کالا و قیمت واحد محصول بررسی می‌شوند تا مقدار منفی در آن‌ها وجود نداشته باشد. این کد فقط موارد نامعتبر را شناسایی و تعداد آن‌ها را گزارش می‌کند تا مشخص شود کدام بخش‌های داده نیازمند اصلاح یا پاک‌سازی هستند. چنین کنترلی باعث می‌شود داده‌هایی که از نظر منطقی قابل قبول نیستند، پیش از ورود به تحلیل‌های بعدی تشخیص داده شوند.

```
Checking logically invalid values...  
Invalid Quantity rows: 0  
Invalid Discount rows: 0  
Invalid UnitPrice in Order_Details: 0  
Invalid Freight rows: 0  
Invalid UnitsInStock rows: 0  
Invalid Product UnitPrice rows: 0
```

شکل ۲۳: بررسی تعداد داده‌های غیرمنطقی منفی برای ستون‌های عددی همواره بزرگتر از ۰

به منظور حصول اطمینان از اعتبار ستون تخفیف^۱ و پایبندی به قوانین کسب‌وکار، بازبینی نهایی جهت اطمینان از قرارگیری تمامی مقادیر تخفیف در بازه منطقی $[0, 1]$ انجام شد. از آنجایی که در فازهای ابتدایی پیش‌پردازش، تمامی مقادیر نامعتبر و خارج از این دامنه شناسایی، فیلتر یا اصلاح شده بودند، اجرای این بررسی در این مرحله تنها نقش «تأییدیه نهایی»^۲ را داشت. نتایج حاصل از این ارزیابی مؤید آن است که داده‌ها کاملاً پاک‌سازی شده و هیچ‌گونه مقدار غیرمجاز یا ناهنجاری در ستون تخفیف وجود ندارد که بتواند محاسبات سود و تحلیل‌های مالی را در مراحل بعدی دچار خطا کند.

```
Number of invalid Discount values: 0
```

شکل ۲۴: بررسی ناهنجاری ستون تخفیف

^۱Discount

^۲Re-validation

حال، هدف در ادامه بررسی یکپارچگی ارجاعی^۱ میان جدول محصولات و جدول دسته‌بندی‌ها است تا اطمینان حاصل شود هر شناسه دسته‌بندی^۲ ثبت‌شده برای یک محصول، واقعاً در جدول دسته‌بندی‌ها وجود دارد. ابتدا وجود جدول دسته‌بندی‌ها در مجموعه داده‌ها کنترل می‌شود و در صورت موجود بودن، شناسه‌های دسته‌بندی محصولات با شناسه‌های معتبر جدول Categories مقایسه می‌شوند. محصولات که دارای شناسه دسته‌بندی نامعتبر باشند، شناسایی و نمونه‌ای از آن‌ها نمایش داده می‌شود. سپس برای پاک‌سازی، فقط محصولاتی در جدول Products نگه داشته می‌شوند که شناسه دسته‌بندی معتبر دارند. تعداد ردیف‌ها قبل و بعد از اصلاح محاسبه می‌شود تا مشخص شود چه تعداد محصول به دلیل دسته‌بندی نامعتبر حذف شده‌اند. این کار باعث می‌شود ارتباط میان محصولات و دسته‌بندی‌ها سازگار باقی بماند و تحلیل‌های مربوط به گروه‌بندی محصولات بر پایه داده‌های معتبر انجام شود.

```
CategoryID referential integrity cleaning completed.  
Removed rows from Products: 1  
Remaining rows in Products: 77
```

شکل ۲۵: بررسی و اصلاح شناسه‌های محصول نامعتبر

در پایان، برای تهیه گزارش کیفیت داده‌ها، تابعی تعریف شد تا تعداد خطاهای شناسایی‌شده در هر جدول و هر قانون اعتبارسنجی را به صورت خلاصه استخراج کند. این تابع با تولید خروجی آماری، امکان مشاهده و مقایسه وضعیت داده‌ها را قبل و بعد از اعمال اصلاحات فراهم می‌سازد. به بیان دیگر، از این گزارش می‌توان برای بررسی میزان خطاهای موجود و ارزیابی اثر پاک‌سازی انجام‌شده استفاده کرد. همچنین جزئیات رکوردهای نامعتبر نیز در خروجی جداگانه نگهداری شد تا در صورت نیاز، پیگیری و بازبینی آن‌ها امکان‌پذیر باشد. در نتیجه، این مرحله به عنوان جمع‌بندی نهایی، تصویری روشن از تعداد خطاها و اصلاحات انجام‌شده ارائه می‌دهد. در انتها تمامی تغییرات ایجاد شده بر دیتابیس را روی فایل‌های سی‌اس‌وی^۳ اعمال می‌کنیم.

^۱Referential Integrity

^۲CategoryID

^۳CSV

Summary before cleaning:					
	Database	Table	Rule	Total Rows	\
0	Before Cleaning	Orders	ShippedDate < OrderDate	835	
1	Before Cleaning	Orders	RequiredDate < OrderDate	835	
2	Before Cleaning	Orders	ShippedDate > RequiredDate	835	
3	Before Cleaning	Orders	Freight < 0	835	
4	Before Cleaning	Order_Details	Quantity <= 0	2140	
5	Before Cleaning	Order_Details	UnitPrice < 0	2140	
6	Before Cleaning	Order_Details	Discount not between 0 and 1	2140	
7	Before Cleaning	Order_Details	Invalid OrderID	2140	
8	Before Cleaning	Products	UnitsInStock < 0	78	
9	Before Cleaning	Products	Product UnitPrice < 0	78	
10	Before Cleaning	Products	Invalid CategoryID	78	
Invalid Count					
0				59	
1				55	
2				89	
3				0	
4				0	
5				0	
6				0	
7				2	
8				0	
9				0	

شکل ۲۶: وضعیت داده‌ها قبل از اصلاح

۳ فاز دوم

۱.۳ اعتبارسنجی داده‌ها

در بخش ابتدایی فاز دوم پروژه، با هدف کنترل صحت ورود اطلاعات و جلوگیری از ثبت داده‌های نادرست در انبار، یک فرم ورود اطلاعات کالا در محیط اکسل^۱ طراحی شد. این فرم در کاربرگ^۲ جدول محصولات^۳ ایجاد گردید و برای ساختاردهی بهتر داده‌ها، ابتدا محدوده مورد نظر با استفاده از ابزار درج جدول^۴ به یک جدول رسمی در اکسل تبدیل شد. استفاده از جدول^۵ باعث شد ستون‌ها دارای عنوان مشخص، فیلتر، قالب‌بندی منظم و قابلیت توسعه خودکار باشند؛ به این معنا که با اضافه شدن رکوردهای جدید، قوانین و قالب جدول نیز به صورت منظم ادامه پیدا کند.

در این فرم، ستون‌های اصلی مورد نیاز برای ثبت اطلاعات کالاها تعریف شدند. این ستون‌ها شامل سریال محصول^۶، نام محصول^۷، دسته‌بندی^۸، کد ردیف انبار^۹، تاریخ تولید^{۱۰}، تاریخ تحویل^{۱۱}، تعداد واحد^{۱۲}، قیمت واحد^{۱۳} و تأیید کیفیت^{۱۴} هستند. هر یک از این فیلدها مطابق خواسته پروژه برای ثبت یک نوع مشخص از اطلاعات در نظر گرفته شده‌اند و برای جلوگیری از ورود داده‌های اشتباه، روی آن‌ها قوانین اعتبارسنجی اعمال شد.

برای انجام اعتبارسنجی، از ابزار اعتبارسنجی داده‌ها^{۱۵} در اکسل استفاده شد. در ستون سریال محصول، ورود سریال کالا به صورت یک کد عددی یکتا تعریف شد و برای راهنمایی کاربر، پیام ورودی مناسب نمایش داده شد؛ به عنوان نمونه، هنگام انتخاب سلول مربوط به سریال کالا، پیام راهنما با عنوان شماره سریال^{۱۶} نمایش داده می‌شود و از کاربر خواسته می‌شود یک کد ۸ رقمی یکتا وارد کند. این کار باعث می‌شود کاربر قبل از ورود اطلاعات، با قالب صحیح داده آشنا شود.

در ستون نام محصول، محدودیت لازم برای ثبت نام کالا در نظر گرفته شد تا مقدار وارد شده با ماهیت این فیلد سازگار باشد و از ثبت داده‌های نامعتبر جلوگیری شود. برای ستون دسته‌بندی نیز از فهرست انتخابی استفاده شد تا کاربر بتواند دسته‌بندی کالا را فقط از میان گزینه‌های مجاز انتخاب کند. به همین منظور، یک کاربرگ جداگانه با نام فهرست‌ها^{۱۷} طراحی شد که در آن گزینه‌های مورد نیاز برای فیلدهای فهرستی قرار گرفتند. این کار باعث شد مقادیر انتخابی در فرم اصلی استاندارد باشند و از نوشتن شکل‌های متفاوت یا اشتباه یک دسته‌بندی جلوگیری شود.

برای ستون کد ردیف انبار نیز قالب مشخصی در نظر گرفته شد تا کد ردیف انبار طبق الگوی خواسته‌شده

¹Microsoft Excel

²Sheet

³Product_Table

⁴Insert Table

⁵Table

⁶Product_Serial

⁷Product_Name

⁸Category

⁹Warehouse_Row_Code

¹⁰Production_Date

¹¹Delivery_Date

¹²Unit_Quantity

¹³Unit_Price

¹⁴Quality_Approval

¹⁵Data Validation

¹⁶Serial Number

¹⁷Lists

وارد شود؛ یعنی ترکیبی از یک حرف بزرگ و یک عدد تکریمی باشد. همچنین برای ستون‌های تاریخ تولید و تاریخ تحویل، اعتبارسنجی مربوط به تاریخ اعمال شد تا تاریخ‌ها در قالب معتبر وارد شوند. در مورد تاریخ تحویل، منطق ورود داده به گونه‌ای در نظر گرفته شد که با تاریخ تولید سازگار و بعد از آن باشد و مقدار نامعتبر ثبت نشود.

[illegible]

شکل ۲۷: تصویر مربوط به طراحی جدول محصولات

۲.۳ پاک‌سازی و تبدیل داده‌ها با ابزار کوئری‌سازی

در ابتدای این بخش، تمامی فایل‌های داده‌ای تمیزشده که در مرحله پیش‌پردازش^۱ تهیه شده بودند، وارد محیط مایکروسافت اکسل شدند. پس از بارگذاری^۲ جدول‌ها، نوع داده^۳ تمامی ستون‌ها مورد بررسی قرار گرفت تا اطمینان حاصل شود هر ستون با نوع داده مناسب خود ذخیره شده است. این مرحله اهمیت زیادی دارد، زیرا تشخیص نادرست نوع داده می‌تواند باعث بروز خطا در محاسبات، مرتب‌سازی، فیلتر کردن^۴ و تحلیل‌های بعدی شود.

در ادامه، ستون‌هایی که نوع داده آن‌ها به درستی تشخیص داده نشده بود اصلاح شدند. برای مثال، ستون‌های تاریخ به قالب تاریخی^۵، ستون‌های عددی به قالب عددی و ستون‌های شناسه یا داده‌های متنی به قالب متنی^۶ تبدیل شدند. این استانداردسازی موجب شد تمامی داده‌ها با ساختاری یکنواخت در اختیار مراحل بعدی پردازش قرار گیرند و از بروز ناسازگاری هنگام انجام محاسبات، ایجاد جدول محوری^۷ و استفاده از فرمول‌های اکسل جلوگیری شود.

برای افزایش خوانایی داده‌ها و کاهش تعداد ستون‌های تکراری، بخشی از اطلاعات مرتبط با یکدیگر در قالب ستون‌های جدید ادغام شدند. در جدول مشتریان و تأمین‌کنندگان، اطلاعات شماره تلفن و نمابر^۸ در یک ستون مشترک قرار گرفت تا تمامی اطلاعات تماس در یک محل قابل مشاهده باشند. در مواردی که مقدار نمابر وجود نداشت، عبارت «بدون نمابر» درج شد تا مشخص باشد مقدار خالی ناشی از نبود این اطلاعات است و نه خطای داده‌ای. همچنین اطلاعات مربوط به کشور، شهر و نشانی در قالب یک ستون جدید با عنوان «موقعیت» ترکیب شدند. این کار باعث شد اطلاعات مکانی هر رکورد به صورت یک مقدار کامل و قابل فهم نمایش داده شود و استفاده از آن در گزارش‌ها، فیلترها و تحلیل‌های مکانی ساده‌تر گردد.

ABC Location
Germany,Berlin,Obere Str. 57
Mexico,México D.F.,Avda. de la Constituci?n 2222
Mexico,México D.F.,Mataderos 2312
UK,London,120 Hanover Sq.
Sweden,Luleå,Berguvsv?gen 8
Germany,Mannheim,Forsterstr. 57
France,Strasbourg,24, place Kléber
Spain,Madrid,C/ Araquil, 67
France,Marseille,12, rue des Bouchers
Canada,Tsawassen,23 Tsawassen Blvd.
UK,London,Fauntleroy Circus
Argentina,Buenos Aires,Cerrito 333
Mexico,México D.F.,Sierras de Granada 9993
Switzerland,Bern,Hauptstr. 29
Brazil,Sao Paulo,Av. dos Lus?adas, 23
UK,London,Berkeley Gardens 12 Brewery
Germany,Aachen,Walserweg 21
France,Nantes,67, rue des Cinquante Otages
UK,London,35 King George

ABC 123 Contact_Info
030-0074321 / 030-0076545
(5) 555-4729 / (5) 555-3745
بدون فکس / (5) 555-3932
(171) 555-7788 / (171) 555-6750
0921-12 34 65 / 0921-12 34 67
0621-08460 / 0621-08924
88.60.15.31 / 88.60.15.32
(91) 555 22 82 / (91) 555 91 99
91.24.45.40 / 91.24.45.41
(604) 555-4729 / (604) 555-3745
بدون فکس / (171) 555-1212
(1) 135-5555 / (1) 135-4892
(5) 555-3392 / (5) 555-7293
بدون فکس / 0452-076545
بدون فکس / (11) 555-7647
(171) 555-2282 / (171) 555-9199

شکل ۲۹: داده‌های موقعیت پس از ادغام در یک ستون واحد

شکل ۲۸: ادغام تلفن و فکس در یک ستون مشترک

¹Preprocessing

²Load

³Data Type

⁴Filtering

⁵Date

⁶Text

⁷Pivot Table

⁸Fax

پس از استانداردسازی ساختار داده‌ها، قالب نمایش برخی ستون‌ها متناسب با ماهیت اطلاعات آن‌ها اصلاح شد. ستون تخفیف به قالب درصد^۱ تبدیل شد تا مقدار واقعی تخفیف برای کاربران قابل درک‌تر باشد. همچنین ستون‌های مرتبط با قیمت، مانند قیمت واحد و قیمت کل، با قالب پولی^۲ نمایش داده شدند تا مقادیر مالی با خوانایی بیشتری ارائه شوند.

علاوه بر این، ستون «توقف تولید» که به صورت مقادیر عددی صفر و یک^۳ ذخیره شده بود، به مقادیر متنی معنادار تبدیل شد؛ به طوری که مقدار ۰ به «در حال تولید» و مقدار ۱ به «توقف تولید» تغییر یافت. این تبدیل باعث شد بدون نیاز به مراجعه به مستندات، وضعیت هر محصول به صورت مستقیم برای کاربران قابل تفسیر باشد.

در همین مرحله، شاخص محبوبیت کالا نیز بر اساس مجموع تعداد فروش و سطح بازفارش^۴ محاسبه شد و محصولات در چهار گروه A, B, C, D طبقه‌بندی شدند. این دسته‌بندی امکان مقایسه سریع محصولات از نظر میزان تقاضا و اهمیت تجاری آن‌ها را فراهم می‌کند و مبنایی برای تحلیل‌های مدیریتی^۵ محسوب می‌شود.

\$ UnitPrice	Quantity	% Discount
14.00	12	0.00%
9.80	10	0.00%
34.80	5	0.00%
18.60	9	0.00%
42.40	40	0.00%
7.70	10	0.00%
42.40	35	15.00%

شکل ۳۰: قالب‌بندی ستون‌های تخفیف، قیمت واحد و قیمت کل

A ^B C ProductPopularity
B
B
C
A
B
D
D
A
A

شکل ۳۱: ایجاد ستون شاخص محبوبیت کالا

^۱ Percentage

^۲ Currency

^۳ Binary Data

^۴ Reorder Level

^۵ Management Analysis

در بخش پایانی، تعدادی ویژگی^۱ جدید از روی داده‌های موجود استخراج شد تا اطلاعات قابل استفاده‌تری برای تحلیل ایجاد شود. هر کالا با استفاده از مقدار موجودی انبار و نقطه سفارش مجدد و کالای سفارش داده تعیین شد و محصولات در وضعیت‌هایی مانند «مطلوب»، «نیازمند سفارش» و «بررسی توقف تولید» قرار گرفتند. سپس با استفاده از قالب‌بندی شرطی^۲، برای هر وضعیت رنگ متفاوتی اختصاص داده شد تا تشخیص شرایط محصولات تنها با مشاهده جدول امکان‌پذیر باشد.

همچنین با استفاده از قیمت واحد، تعداد کالا و میزان تخفیف، هزینه نهایی هر سفارش محاسبه و در قالب ستون «قیمت کل» ثبت شد. این ویژگی بدون نیاز به انجام محاسبات مجدد، امکان بررسی ارزش مالی سفارش‌ها و تحلیل‌های مرتبط با فروش را فراهم می‌کند و می‌تواند در تهیه گزارش‌های مدیریتی مورد استفاده قرار گیرد. این فرآیند استخراج ویژگی^۳، گام نهایی برای تبدیل داده‌های خام به اطلاعات ارزشمند جهت تصمیم‌گیری بود.

OrderID	TotalCostOfOrder
10248	440
10249	1863.4
10250	1552.6
10251	654.06
10252	3597.9
10253	1444.8
10254	556.62
10255	2490.5
10256	517.8
10257	1119.9
10258	1614.88
10259	100.8

شکل ۳۳: محاسبه ارزش سفارش‌ها

InventoryStatus
Optimal
Optimal
Optimal
Ordered - In Transit
Ordered - In Transit
Ordered - In Transit
Optimal
Production Stopped - Review
Needs Reorder
Optimal
Optimal
Optimal
Ordered - In Transit
Optimal
Needs Reorder
Optimal
Optimal
Optimal

شکل ۳۲: تقسیم وضعیت کالا به ۴ حالت: مطلوب، در حال ارسال، نیازمند سفارش، توقف تولید

¹ Feature

² Conditional Formatting

³ Feature Extraction

۳.۳ مدل‌سازی و تحلیل داده‌ها

در بخش مدل‌سازی و تحلیل داده‌ها، ابتدا تمامی جداول پایگاه داده وارد محیط مدل داده^۱ اکسل شدند. در این مرحله، ارتباطات منطقی میان جداول (از جمله جداول سفارشات، محصولات، تأمین‌کنندگان، شرکت‌های حمل‌ونقل و دسته‌بندی‌ها) بر اساس کلیدهای اصلی و کلیدهای خارجی به‌طور کامل برقرار گردید. برقرار ساختن این ارتباطات^۲ به سیستم اجازه می‌دهد تا داده‌ها را از جداول مختلف به‌صورت یکپارچه فراخوانی و تحلیل کند.

پس از حصول اطمینان از یکپارچگی روابط، پنج تحلیل کلیدی با بهره‌گیری از ابزارهای جدول محوری و نمودار محوری^۳ به‌منظور استخراج بینش‌های تجاری طراحی و پیاده‌سازی شد.

۱.۳.۳ نمایش مقدار سفارش جدید برای هر دسته بندی در جدول محوری

در تحلیل نخست، با هدف پایش وضعیت تأمین کالا، مجموع مقدار سفارشات در راه^۴ به تفکیک هر نام دسته‌بندی^۵ استخراج شد. این تحلیل به مدیران کمک می‌کند تا دید دقیقی نسبت به حجم کالاهای در حال ورود به انبار برای هر گروه کالایی داشته باشند.

CategoryName	Sum of UnitsOnOrder
Beverages	60
Condiments	170
Confections	180
Dairy Products	140
Grains/Cereals	90
Meat/Poultry	0
Produce	20
Seafood	120
Grand Total	780

شکل ۳۴: تحلیل اول: نمایش مقدار سفارش جدید برای هر دسته بندی

۲.۳.۳ تحلیل هزینه حمل به تفکیک کشور و شرکت حمل و نقل همراه با نمودار

در تحلیل دوم، به منظور ارزیابی دقیق هزینه‌های لجستیک، شاخص هزینه حمل‌ونقل بر اساس تقاطع دو بعد «کشور مقصد»^۶ و «شرکت حمل‌ونقل»^۷ مورد بررسی قرار گرفت و خروجی آن به صورت یک نمودار ستونی خوشه‌ای ارائه گردید.

^۱Data Model

^۲Relationships


^۳PivotChart

^۴UnitsOnOrder

^۵CategoryName

^۶ShipCountry


^۷Shippers



شکل ۳۵: تحلیل دوم: توزیع هزینه‌های لجستیک و حمل‌ونقل بر اساس کشور مقصد و شرکت باربری

۳.۳.۳ تحلیل تقاضا و قیمت واحد کالا و نمایش بصری مقدار فروش هر کالا

برای تحلیل سوم، رفتار بازار در قبال قیمت‌گذاری محصولات ارزیابی شد؛ به این صورت که «مقدار کل تقاضا»^۱ در مقابل «میانگین قیمت واحد»^۲ هر محصول قرار گرفت و این نتایج در قالب نمودار ترکیبی^۳ با استفاده از محور ثانویه^۴ نمایش داده شد تا همبستگی میان قیمت و حجم فروش به‌وضوح قابل درک باشد.



شکل ۳۶: تحلیل سوم: همبستگی میانگین قیمت واحد و میزان تقاضا (نمودار ترکیبی)

۴.۳.۳ تحلیل ارزش کل موجودی انبار به تفکیک تأمین‌کنندگان

در ادامه و برای تحلیل چهارم، به منظور برآورد ارزش سرمایه در گردش موجود در انبار، ابتدا یک ستون محاسباتی^۵ اختصاصی با فرمول ضرب موجودی در قیمت واحد

$$\text{UnitInStock} * \text{UnitPrice}$$

در جدول محصولات ایجاد گردید. سپس ارزش کل موجودی انبار به تفکیک شرکت‌های تأمین‌کننده محاسبه و در یک نمودار میله‌ای تجمیع شد.


¹Total Quantity Sold

²Average Unit Price

³Combo Chart

⁴Secondary Axis

⁵CalculatedColumn



شکل ۳۷: تحلیل چهارم: برآورد ارزش سرمایه در گردش انبار به تفکیک تأمین کنندگان

۵.۳.۳ تحلیل درآمد کل شرکت به تفکیک کشور مقصد با استفاده از برش گر و نمودار

در تحلیل پنجم که به بررسی درآمد کل شرکت اختصاص داشت، ابتدا به منظور تضمین یکپارچگی داده‌ها، ارتباط استاندارد میان جدول جزئیات پاکسازی شده سفارش‌ها^۱ و جدول سفارش‌ها از طریق شناسه سفارش^۲ برقرار گردید. پس از اتصال این جداول، مجموع هزینه سفارش‌ها^۳ به عنوان شاخص درآمد کل، به تفکیک کشورهای مقصد محاسبه و مصورسازی شد.


به منظور ارتقای سطح کارایی و تعاملی کردن این گزارش پایانی، ابزار فیلتر گرافیکی یا برش‌دهنده بر روی فیلد تاریخ سفارش^۴ پیاده‌سازی گردید. این ویژگی کاربردی به مدیران سازمان امکان می‌دهد تا روند درآمد‌های جغرافیایی را به صورت پویا در بازه‌های زمانی مختلف پایش کرده و تصمیم‌گیری‌های کلان مدیریتی را با سرعت و دقت بیشتری انجام دهند.

¹ CleanOrderDetails

² OrderID

³ TotalCostOfOrder

⁴ OrderDate



شکل ۳۸: تحلیل پنجم: درآمد جغرافیایی کل شرکت همراه با فیلتر پویای تاریخ سفارش

۴.۳ خودکارسازی با ماکرو و برنامه‌نویسی

در بخش پایانی پروژه و با هدف خودکارسازی^۱ عملیات انبارداری، ارتقای دقت در مدیریت اطلاعات کالاها و به حداقل رساندن خطای انسانی، فرآیند پردازش داده‌ها از طریق توسعه یک ماکرو^۲ در محیط برنامه‌نویسی ویژوال بیسیک برای اپلیکیشن‌ها^۳ پیاده‌سازی شد. این برنامه که در قالب زیرروال Process WarehouseData توسعه یافته است، فرآیندهای محاسباتی، قالب‌بندی شرطی و تفکیک داده‌ها را به صورت پویا و در قالب مراحل پیوسته مدیریت می‌کند.

در وهله نخست، سیستم با شناسایی خودکار آخرین ردیف فعال جدول بر اساس ستون تعداد کالا، یک حلقه تکرار^۴ را بر روی تمامی ردیف‌ها آغاز می‌کند. در طول این پیمایش، مقادیر مربوط به تعداد کالا و قیمت واحد پس از اعتبارسنجی عددی و اطمینان از خالی نبودن سلول‌ها، در یکدیگر ضرب شده و به صورت متوالی در متغیر ارزش کل^۵ انباشته می‌شوند. در نهایت، حاصل این محاسبات به همراه عنوان مشخص در سلول‌های هدف درج شده و برای جلب توجه کاربر، با رنگ زرد متمایز می‌گردد.

هم‌زمان با این محاسبات، برنامه وضعیت کنترل کیفیت کالاها را در ستون مربوطه ارزیابی می‌کند تا قالب‌بندی ظاهری جدول را به صورت پویا تغییر دهد. بر اساس منطق شرطی تعریف‌شده، ردیف‌هایی که وضعیت آن‌ها تاییدشده^۶ باشد با رنگ سبز ملایم و موارد ردشده^۷ با رنگ قرمز ملایم متمایز می‌شوند. این در حالی است که ردیف‌های در حال انتظار^۸ بدون تغییر رنگ و با قالب پیش‌فرض باقی می‌مانند تا ساختار بصری جدول به راحتی وضعیت هر کالا را به نمایش بگذارد.

در نهایت، فرآیند استخراج داده‌ها به منظور آرشیو اقلام مجاز و انتقال آن‌ها به یک کاربرگ جدید انجام می‌گیرد. بدین منظور، برنامه ابتدا وجود کاربرگ مجزایی به نام موارد پذیرفته شده^۹ را بررسی می‌کند؛ در

^۱Automation

^۲Macro

^۳VBA (Visual Basic for Applications)

^۴Loop

^۵totalValueSum

^۶Approved

^۷Rejected

^۸Pending

^۹Approved_Items

صورت عدم وجود، این کاربرگ ایجاد و ردیف عناوین^۱ به آن منتقل می‌شود و در صورت وجود، داده‌های قبلی آن پاکسازی می‌گردند تا اطلاعات جدید جایگزین شوند. در طول پیمایش حلقه، هر ردیفی که وضعیت تاییدشده داشته باشد، به طور خودکار به این کاربرگ جدید کپی می‌شود.

پس از اتمام موفقیت‌آمیز تمامی این مراحل، یک جعبه پیام^۲ برای اطلاع‌رسانی به کاربر نمایش داده شده و کل پروژه در فایلی با پسوند پشتیبانی‌کننده از ماکرو در اکسل^۳ ذخیره می‌گردد تا پایداری و قابلیت اجرای مجدد این فرآیند خودکار تضمین شود.

[illegible]

شکل ۳۹: نمونه‌ای از نحوه عملکرد کد

A	B	C	D	E	F	G	H	I
Product_Serial	Product_Name	Category	Warehouse_Code	Production_Date	Delivery_Date	Unit_Quantity	Unit_Price	Quality_Approval
22448866	Fish	Seafood	A8	2006/11/12	2006/11/14	50	5.00	Approved

شکل ۴۰: کاربرد جدید ساخته شده برای کالاهای پذیرفته شده

¹Header²MessageBox³xlsm

۱.۴ طراحی جداول و روابط

در این مرحله از پروژه، پیاده‌سازی پایگاه داده تراکنشی^۱ شرکت نورث‌ویند در محیط نرم‌افزار مایکروسافت اکسس^۲ با هدف ایجاد یک سیستم یکپارچه برای مدیریت چرخه فروش و تأمین آغاز گردید. فرآیند طراحی با تحلیل دقیق فایل‌های منبع و آماده‌سازی آن‌ها جهت انتقال به بانک اطلاعاتی صورت پذیرفت. پیش از هرگونه اقدام، تمامی فایل‌های سی‌اس‌وی به‌منظور درک دقیق ساختار فیلدها و تعیین نوع داده‌ها، در محیط دفترچه یادداشت ویندوز^۳ بررسی شدند. این پیش‌بینی فنی سبب شد تا در هنگام استفاده از جادوگر واردسازی متن^۴، تنظیمات مربوط به جداکننده^۵ بر روی کاما و مشخص‌کننده متن^۶ بر روی نقل‌قول دوتایی^۷ تنظیم گردد؛ این امر از شکستگی داده‌های متنی که حاوی کاراکتر کاما بودند جلوگیری کرده و سلامت اطلاعات را در هنگام ورود تضمین نمود.

بمنظور ارتقای دقت در مدیریت زمان و تاریخ، از بخش تنظیمات پیشرفته واردسازی^۸ استفاده شد. با تنظیم کدگذاری بر روی یونیکد^۹ و انتخاب قالب تاریخ^{۱۰} (سال-ماه-روز) و فعال کردن تیک leading zeros in dates تاریخ سفارش^{۱۱} و تاریخ استخدام^{۱۲} بدون بروز خطای تبدیل، به نوع داده استاندارد تاریخ و زمان^{۱۳} مجهز شدند. پس از استقرار داده‌ها در جداول، ساختار کلیدهای اصلی برای تمامی جداول پایه تعریف گردید تا یکتایی هر رکورد تضمین شود. در این میان، برای جداول واسط^{۱۴} همچون جزئیات سفارش^{۱۵} و قلمرو کارکنان^{۱۶}، از کلید اصلی مرکب استفاده شد تا منطق روابط چندبه‌چند^{۱۷} به درستی پیاده‌سازی شده و از ثبت رکوردهای تکراری در یک تراکنش واحد جلوگیری شود.

در گام نهایی، معماری ارتباطی پایگاه داده در بخش روابط شکل گرفت. با تعریف کلیدهای خارجی، مجموعاً ۱۰ رابطه منطقی از نوع یک‌به‌چند^{۱۸} میان موجودیت‌های سیستم برقرار شد. نکته حائز اهمیت در این بخش، فعال‌سازی گزینه اجبار یکپارچگی ارجاعی^{۱۹} در تمامی روابط بود. این محدودیت سیستمی با جلوگیری از ایجاد رکوردهای یتیم^{۲۰} و اطمینان از وجود کلیدهای مرجع پیش از ثبت داده‌های وابسته، پایداری و صحت منطقی پایگاه داده را برای مراحل بعدی یعنی طراحی پرس‌وجوها و گزارش‌های مدیریتی تضمین نمود.

¹ Transactional Database

² Microsoft Access

³ Notepad

⁴ Import Text Wizard

⁵ Delimiter

⁶ Text Qualifier

⁷ Double Quote

⁸ Advanced Import Specifications

⁹ UTF-8

¹⁰ YMD

¹¹ OrderDate

¹² HireDate

¹³ Date/Time

¹⁴ Junction Tables

¹⁵ Order Details


¹⁶ EmployeeTerritories

¹⁷ Many-to-Many

¹⁸ One-to-Many

¹⁹ Enforce Referential Integrity

²⁰ Orphan Records



شکل ۴۱: نمودار روابط جداول در پایگاه داده

۲.۴ طراحی کوئری‌ها

۱.۲.۴ نشان دادن نام محصول و قیمت نهایی آن پس از اعمال تخفیف

پس از تثبیت ساختار جداول و برقراری روابط منطقی میان موجودیت‌ها، فرآیند پیاده‌سازی پرس‌وجوها^۱ به منظور پاسخگویی به نیازهای تحلیلی کسب‌وکار و استخراج اطلاعات ارزش‌آفرین آغاز گردید. در وهله نخست، هدف سیستم بر محاسبه قیمت نهایی محصولات پس از اعمال تخفیف‌های تجاری متمرکز شد. برای پیاده‌سازی این سناریو، پرس‌وجوی محاسباتی ویژه‌ای طراحی گردید که در آن با استفاده از فرمول‌نویسی در یک ستون محاسباتی، مقدار نهایی با کسر ۲۰ درصد تخفیف تعیین شد. در این فرمول که به صورت:

$$\text{FinalPrice: Round}([\text{UnitPrice}] * 0.8)$$

تعریف گردید، از تابع گرد کردن^۲ استفاده شد تا خروجی نهایی به نزدیک‌ترین عدد صحیح تبدیل شود؛ این رویکرد محاسباتی علاوه بر ساده‌سازی فرآیندهای مالی، انطباق کاملی با استانداردهای سیستم‌های حسابداری و صدور فاکتور دارد.

^۱ Queries

^۲ Round

ProductName	FinalPrice				
Chai	14				
Chang	15				
Aniseed Syrup	8				
Chef Anton's Ca	18				
Chef Anton's Gu	17				
Grandma's Boys	20				
Uncle Bob's Org	24				
Northwoods Cr	32				
Mishi Kobe Niku	78				
Ikura	25				
Queso Cabrales	17				
Queso Mancheg	30				
Konbu	5				
Tofu	19				
Genen Shouyu	12				
Pavlova	14				
Alice Mutton	31				
Carnarvon Tiger	50				
Teatime Chocol	7				
Sir Rodney's Ma	65				

شکل ۴۳: نتیجه کوئری

Field:	ProductID	ProductID	ProductID	ProductID	ProductID
Table:	Products				
Sort:					
Show:	☒	☒	☒	☒	☒
Criteria:					
or:					

شکل ۴۲: کوئری نام محصول و قیمت نهایی آن پس از اعمال تخفیف

۲.۲.۴ نشان دادن نام هر محصول به همراه تعداد کل سفارش ها

در گام بعدی و به منظور بررسی رفتار بازار، پرس و جوی تحلیل محبوبیت و میزان تقاضای محصولات طراحی و اجرا شد. این ساختار تحلیلی با ادغام^۱ جدول کالاها و جزئیات سفارش ها بر اساس فیلد مشترک شناسه کالا^۲ شکل گرفت. سیستم با بهره گیری از توابع تجمعی^۳، کالاها را بر اساس نام تجاری آن ها گروه بندی^۴ نموده و تعداد دفعات ثبت هر کالا در فاکتورهای مختلف را با استفاده از تابع شمارش^۵ بر روی فیلد شناسه سفارش^۶ محاسبه کرد. خروجی حاصل از این تحلیل، مدیران زنجیره تأمین را قادر می سازد تا اقلام پرتقاضا را شناسایی کرده و تصمیمات دقیق تری در خصوص کنترل موجودی انبار اتخاذ نمایند.

ProductName	CountOfOrder				
Alice Mutton	37				
Aniseed Syrup	12				
Boston Crab Me	41				
Camembert Pie	51				
Carnarvon Tiger	27				
Chai	38				
Chang	44				
Chartreuse vert	30				
Chef Anton's Ca	20				
Chef Anton's Gu	10				
Chocolade	6				
Côte de Blaye	24				
Escargots de Bo	18				
Filo Mix	29				
Flotemysost	42				
Geitost	32				
Genen Shouyu	6				
Gnocchi di nonn	50				
Gorgonzola Teli	51				

شکل ۴۵: نتیجه کوئری

Field:	ProductID	ProductID	ProductID	ProductID	ProductID	OrderID	OrderID	OrderID	OrderID
Table:	Products					Order_Details			
Sort:									
Show:	☒	☒	☒	☒	☒	☒	☒	☒	☒
Criteria:									
or:									

شکل ۴۴: کوئری نام هر محصول به همراه تعداد کل سفارش های ثبت شده

۳.۲.۴ نشان دادن نام هر کارمند به همراه تعداد کل سفارش ها توسط او

در نهایت، بخش ارزیابی عملکرد و بهره وری منابع انسانی با طراحی پرس و جوی سوم پیاده سازی گردید. هدف از این بخش، سنجش کارایی کارکنان بخش فروش بر اساس حجم تراکنش های ثبت شده توسط آنان بود.

¹Join

²ProductID

³Aggregate Functions

⁴Group By


⁵Count

⁶OrderID

بدین منظور، با برقراری پیوند میان جدول کارکنان و جدول سفارش‌ها از طریق شناسه کارمند^۱، اطلاعات این دو بخش یکپارچه گردید. در این ساختار، سیستم پس از گروه‌بندی سوابق بر اساس نام خانوادگی کارکنان، تعداد کل سفارش‌های ثبت‌شده توسط هر فرد را از طریق اعمال تابع شمارش بر روی فیلد شناسه سفارش استخراج نمود. خروجی این پرس‌وجو به عنوان یک شاخص کلیدی عملکرد در ارزیابی‌های دوره‌ای سازمان و تخصیص پاداش‌های فروش نقش مؤثری ایفا می‌کند.

Product Name	CountOfOrder
Alice Mutton	37
Aniseed Syrup	12
Boston Crab Me	41
Camembert Pier	51
Carnarvon Tiger	27
Chai	38
Chang	44
Chartreuse vert	30
Chef Anton's Ca	20
Chef Anton's Gu	10
Chocolate	6
Côte de Blaye	24
Escargots de Bo	18
Filo Mix	29
Flotemysost	42
Geitost	32
Genen Shouyu	6
Gnocchi di nonn	50
Gorgonzola Teli	51

شکل ۴۷: نتیجه کوئری



شکل ۴۶: نتیجه کوئری

۳.۴ طراحی فرم‌های پایگاه داده

یکی از اصول بنیادین در توسعه سیستم‌های مدیریت پایگاه داده^۲، جداسازی کامل لایه کاربر^۳ از لایه داده^۴ به منظور تسهیل تعامل کاربران نهایی، کاهش ضریب خطای انسانی در ورود اطلاعات و حفظ یکپارچگی ساختاری سیستم است. در راستای تحقق این هدف، فرآیند طراحی و پیاده‌سازی واسط‌های کاربری متعددی در دستور کار قرار گرفت. در گام نخست، واسط کاربری ویژه‌ای جهت مدیریت اطلاعات مشتریان طراحی گردید. از آنجا که دسترسی مستقیم اپراتورها به جداول خام پایگاه داده مخاطرات امنیتی فراوانی نظیر حذف یا تغییر ناخواسته داده‌های حیاتی را به همراه دارد، فرمی مستقل تحت عنوان ثبت مشتری جدید^۵ ایجاد و به جدول مشتریان متصل شد. در طراحی این فرم، فیلدهای کلیدی نظیر شناسه مشتری (مانند نمونه تخصیص‌یافته^۶ برای شرکت آلفردز^۷)، نام رابط تماس، سمت، نشانی دقیق پستی، شهر، کشور، تلفن و فکس با چیدمانی عمودی و منظم قرار گرفتند. همچنین به منظور استقلال رابط کاربری از منوهای

^۱EmployeeID

^۲Database Management System

^۳User Interface

^۴Data Layer

^۵Add New Customer

^۶ALFKI

^۷Alfreds Futterkiste

پیش فرض نرم افزار، دکمه های عملیاتی کنترلی^۱ شامل ایجاد مشتری جدید^۲، ذخیره اطلاعات^۳ و خروج^۴ در پایین صفحه تعبیه گردید تا اپراتور بدون مواجهه با پیچیدگی های محیط طراحی پایگاه داده، به راحتی به مدیریت داده ها بپردازد.

شکل ۴۸: فرم ثبت مشتری جدید

در ادامه فرآیند توسعه، فرم ثبت سفارش های جدید^۵ به عنوان یکی از پیچیده ترین بخش های سیستم پیاده سازی شد؛ چرا که ثبت هر سفارش مستلزم برقراری ارتباط همزمان میان موجودیت های متعددی نظیر مشتریان، کارمندان و اقلام کالا است. ساختار این بخش به صورت یک فرم اصلی^۶ متصل به جدول سفارش ها و یک فرم فرعی^۷ با عنوان جزئیات سفارش ها پیاده سازی گردید که از طریق فیلد کلید خارجی شناسه سفارش^۸ به یکدیگر پیوند داده شده اند. جهت تضمین صحت ورود داده ها و جلوگیری از بروز خطاهای مرجع، برای انتخاب کارمند و مشتری از جعبه های ترکیبی^۹ استفاده شد که اطلاعات خود را به صورت پویا

^۱ Command Buttons

^۲ New Customer

^۳ Save

^۴ Close

^۵ New Order Form

^۶ Main Form

^۷ Order Details Subform

^۸ OrderID

^۹ Combo Boxes

از جداول مرجع فراخوانی می‌کنند. به منظور افزایش سرعت کاربری، فیلدهای مربوط به مشخصات ارسال کالا به گونه‌ای پی‌کردنی شدند که به محض انتخاب مشتری، اطلاعات نشانی وی به صورت پیش‌فرض در فیلدهای مربوطه درج شود، هرچند امکان ویرایش دستی این فیلدها برای ارسال به مقاصد متفاوت نیز وجود دارد. در این فرم، محاسبات مالی به صورت کاملاً پویا پیاده‌سازی گردید؛ به طوری که در فرم فرعی، یک کنترل محاسباتی^۱ با عنوان جمع ردیف^۲ با فرمول ضرب قیمت واحد در تعداد پس از کسر تخفیف، جمع هر قلم کالا را مشخص می‌سازد (مانند محاسبه مبلغ ۱۶۸ دلار برای ۱۲ عدد از یک کالای Queso Cabrales با قیمت واحد ۱۴ دلار و تخفیف صفر درصد). در نهایت، در فرم اصلی با بهره‌گیری از فرمول محاسباتی ریاضی به صورت:

$$\text{Order Total} = \text{Sum}([\text{UnitPrice}] * [\text{Quantity}] * (1 - [\text{Discount}])) + \text{Nz}([\text{Freight}])$$

• جمع کل فاکتور^۳ با احتساب هزینه حمل و نقل محاسبه می‌گردد که در سفارش نمونه شماره ۱۰۲۴۸، مقدار نهایی پس از جمع مبالغ اقلام و هزینه حمل ۳۸.۳۲ دلاری، معادل ۳۸.۴۷۲ دلار در فیلد مربوطه منعکس شده است.

ProductID	OrderID	UnitPrice	Quantity	Discount	LineTotal
Queso Cabrales	10248	14	12	0	168
Singaporean Hokkien Fried Mee	10248	9.8	10	0	98
Mozzarella di Giovanni	10248	34.8	5	0	174
	10248				

شکل ۴۹: فیلدهای فرم ثبت سفارش جدید

به منظور مدیریت پویای عملیات روی سفارش‌ها، مجموعه‌ای از دکمه‌های کنترلی کلیدی شامل ثبت سفارش جدید^۴، ذخیره سفارش^۵، حذف سفارش^۶ و چاپ فاکتور^۷ در قالب یک نوار ابزار اختصاصی طراحی

^۱ Calculated Control

^۲ LineTotal

^۳ Order Total

^۴ New Order

^۵ Save Order

^۶ Delete Order

^۷ Print Invoice

و در فرم سفارش‌ها ادغام شد تا دسترسی کاربر به فرآیندهای سیستمی به بهینه‌ترین شکل ممکن برقرار گردد.



شکل ۵۰: ایجاد قابلیت و دکمه پرینت فاکتور برای سفارش

بخش پایانی این فاز به طراحی قابلیت چاپ فاکتور فروش اختصاصی اختصاص یافت تا امکان ارائه خروجی رسمی به مشتریان فراهم گردد. بدین منظور، ابتدا گزارشی^۱ تحت عنوان فاکتور^۲ طراحی شد که اطلاعات خود را از ادغام جداول مختلف استخراج کرده و ساختاری استاندارد شامل شناسه سفارش، تاریخ، نام مشتری، تلفن، نام محصول، تعداد، قیمت واحد، درصد تخفیف، جمع ردیف، هزینه حمل و نقل و جمع کل سفارش را نمایش می‌دهد. این گزارش در حالت پیش‌فرض تمام اسناد ثبت‌شده در سیستم (نظیر سفارش‌های شماره ۱۰۲۴۸، ۱۰۲۴۹ و ۱۰۲۵۰) را به صورت متوالی و گروه‌بندی شده نمایش می‌دهد.

Orders										
Invoice										
OrderID	OrderDate	CompanyName	Phone	ProductName	Quantity	UnitPrice	Discount	Total	Freight	Order Total
10248	7/4/1996	Toms Spezialit?ten	0251-031259	Mozzarella di Giovanni	5	\$34.80	0.00%	\$174.00		
				Queso Cabrales	12	\$14.00	0.00%	\$168.00		
				Singaporean Hokkien Fried Mei	10	\$9.80	0.00%	\$98.00		
									\$32.38	
										\$472.38
10249	7/5/1996	Toms Spezialit?ten	0251-031259	Manjimup Dried Apples	40	\$42.40	0.00%	\$1,696.00		
				Tofu	9	\$18.60	0.00%	\$167.40		
									\$11.61	
										\$1,875.01
10250	7/8/1996	Hanari Carnes	(21) 555-0091	Jack's New England Clam Chow	10	\$7.70	0.00%	\$77.00		
				Louisiana Fiery Hot Pepper Sau	15	\$16.80	15.00%	\$214.20		
				Manjimup Dried Apples	35	\$42.40	15.00%	\$1,261.40		
									\$65.83	
										\$1,618.43

شکل ۵۱: ایجاد گزارش فاکتور، شامل فاکتور تمام سفارش‌ها

چالش اصلی در این بخش، فیلتر کردن هوشمند گزارش بر اساس سفارشی بود که کاربر در لحظه روی فرم ثبت سفارش مشاهده می‌کند. برای حل این مسئله، ماکروی ویژه‌ای برای دکمه چاپ سفارش تعریف شد که با اعمال شرط فیلتر^۳ به صورت `[OrderID]=[Forms]![Orders]![OrderID]` موتور پایگاه داده را ملزم می‌سازد تا گزارش خروجی را دقیقاً منطبق بر شناسه فاکتور فعال در فرم (برای نمونه سفارش شماره ۱۰۲۴۸) فیلتر کرده و خروجی تک‌صفحه‌ای اختصاصی آن را جهت چاپ آماده سازد. این رویکرد

¹ Report

² Invoice

³ Where Condition

ساختاریافته علاوه بر افزایش سرعت عمل کاربران سیستم، به طور کامل مانع از بروز تداخل اطلاعاتی در فرآیندهای مالی می‌گردد.

Invoice										
OrderID	OrderDate	CompanyName	Phone	ProductName	Quantity	UnitPrice	Discount	Total	Freight	Order Total
10248	7/4/1996	Toms Spezialit	ten 0251-031259	Mozzarella di Giovanni	5	\$34.80	0.00%	\$174.00		
				Queso Cabrales	12	\$14.00	0.00%	\$168.00		
				Singaporean Hokkien Fried M	10	\$9.80	0.00%	\$98.00		
									\$32.38	
										\$472.38

شکل ۵۲: فاکتور ایجاد شده برای سفارش ۱۰۲۴۸

۴.۴ طراحی گزارش‌های مدیریتی و تحلیلی

۱.۴.۴ گزارش عملکرد و ارزش‌گذاری گروه‌های کالایی

در فرآیند طراحی سیستم گزارش‌دهی جهت ارزیابی عملکرد گروه‌های کالایی، رویکرد چندمرحله‌ای در طراحی پرس‌وجوها^۱ به عنوان استراتژی اصلی برگزیده شد تا علاوه بر تضمین دقت در محاسبات پیچیده، کارایی سیستم در مواجهه با حجم بالای داده‌ها حفظ گردد. در گام نخست، با هدف سنجش تنوع محصولات، پرس‌وجوی اختصاصی جهت اتصال جداول دسته‌بندی و محصولات طراحی شد که در آن با بهره‌گیری از تابع شمارش بر روی شناسه کالا^۲، میزان تنوع محصولات در هر گروه استخراج گردید. در گام دوم، برای سنجش دقیق میزان فروش، پرس‌وجوی دیگری با پیوند جداول دسته‌بندی، کالاها و جزئیات سفارشات ایجاد شد تا مجموع درآمد خالص هر گروه با استفاده از تابع محاسباتی زیر در قالب ارز^۳ تعیین گردد:

SalesAmount: CCur(Sum([UnitPrice] * [Quantity] * (1 - [Discount])))

این خروجی با اعمال ترتیب نزولی^۴ تنظیم گردید تا گروه‌های پیشرو در سودآوری در اولویت نمایش قرار گیرند. در نهایت، با ادغام این زیرمجموعه‌ها در یک پرس‌وجوی جامع، بستری برای تغذیه ابزارهای تحلیل بصری فراهم شد.

Report1_CategoryProductCount	
CategoryName	CountOfProd
Beverages	12
Condiments	12
Confections	13
Dairy Products	10
Grains/Cereals	7
Meat/Poultry	6
Produce	5
Seafood	12

شکل ۵۴: خروجی تنوع گروه‌ها

Report1_SaleAmount		
CategoryName	CountOfProd	SalesAmount
Beverages	404	\$267,868.18
Dairy Products	366	\$234,507.29
Confections	334	\$167,357.23
Meat/Poultry	173	\$163,022.36
Seafood	330	\$131,261.74
Condiments	216	\$106,047.09
Produce	136	\$99,984.58
Grains/Cereals	196	\$95,744.59

شکل ۵۳: خروجی مجموع فروش گروه‌ها

^۱ Multi-stage Queries

^۲ CountProductID


^۳ Currency

^۴ Descending


Report1_CategoryReport X		
CategoryName	CountOfProd	SalesAmount
Beverages	12	\$267,868.18
Dairy Products	10	\$234,507.29
Confections	13	\$167,357.23
Meat/Poultry	6	\$163,022.36
Seafood	12	\$131,261.74
Condiments	12	\$106,047.09
Produce	5	\$99,984.58
Grains/Cereals	7	\$95,744.59

شکل ۵۵: تجميع دو خروجی

برای نمایش بهینه این داده‌ها، دو نوع نمودار با رویکردهای مدیریتی متفاوت طراحی گردید؛ نمودار نخست که به صورت ستونی ساده^۱ پیاده‌سازی شده است، با نمایش مستقیم سهم هر گروه از کل درآمد، امکان شناسایی سریع دسته‌های پربازده نظیر نوشیدنی‌ها^۲ و لبنیات^۳ را فراهم می‌آورد. در مقابل، نمودار دوم که یک نمودار ترکیبی دو محوره^۴ است، با هدف کشف رابطه استراتژیک میان تنوع کالا و بازدهی مالی طراحی شده است. در این نمودار، میزان فروش بر روی ستون‌های محور اصلی و تعداد کالاها به صورت خطی بر روی محور ثانویه ترسیم شده است. تحلیل این ساختار ترکیبی حقایق مدیریتی مهمی را آشکار می‌سازد؛ به عنوان نمونه، مشاهده می‌شود که برخی دسته‌ها مانند شیرینی‌جات^۵ با وجود دارا بودن بیشترین تنوع کالایی، در رتبه سوم فروش قرار دارند، در حالی که دسته لبنیات با تنوع کمتر، بازدهی مالی بالاتری ثبت کرده است. این تحلیل بصری به مدیران زنجیره تأمین اجازه می‌دهد تا به جای افزایش بی‌رویه تنوع کالا، بر بهینه‌سازی سبد محصولات پرتقاضا تمرکز نموده و از انباشت سرمایه در بخش‌های کم‌بازده جلوگیری کنند.



شکل ۵۷: نمایش نمودار تحلیلی تاثیر تنوع بر میزان فروش هر گروه



شکل ۵۶: نمایش نمودار مجموع فروش هر گروه

¹Column Chart

²Beverages

³Dairy Products

⁴Dual-Axis Combo Chart

⁵Confections

۲.۴.۴ گزارش تحلیل رفتار خرید مشتریان

ارزیابی مستمر رفتار مشتریان و شناسایی مخاطبان کلیدی، نقشی حیاتی در بهینه‌سازی زنجیره عرضه و اجرای موفق طرح‌های بازاریابی هدفمند^۱ ایفا می‌کند. به منظور تحلیل دقیق رفتار خرید مشتریان از دو جنبه حجم مبادلات مالی و تعداد دفعات سفارش، یک معماری اطلاعاتی چندلایه در پایگاه داده طراحی گردید. فرآیند پیاده‌سازی با طراحی پرس‌وجوی پایه با عنوان Report2_CustomersListOnTotalPurchase آغاز شد که طی آن، پیوند میان جداول مشتریان، سفارش‌ها و جزئیات سفارش‌ها از طریق فیلدهای کلیدی شناسه مشتری و شناسه سفارش^۲ برقرار گردید تا امکان ردیابی کل فرآیند خرید از مشخصات خریدار تا جزئی‌ترین اقلام سبد کالا فراهم شود. در ساختار این پرس‌وجو، شناسه مشتری مبنای گروه‌بندی قرار گرفت و حجم کل خرید هر مشتری با اعمال فرمول محاسباتی زیر بر روی قیمت واحد، تعداد و اعمال درصد تخفیف استخراج شد:

$$\text{TotalPurchase} = \text{Sum}(\text{CCur}([\text{UnitPrice}] * [\text{Quantity}] * (1 - [\text{Discount}])))$$

این فیلد محاسباتی با اعمال ساختار مرتب‌سازی نزولی^۳ تنظیم گردید تا مشتریان استراتژیک در صدر فهرست قرار گیرند. هم‌زمان، فراوانی سفارش‌های هر مشتری با استفاده از تابع Count(OrderID) محاسبه شد و پس از صحت‌سنجی خروجی جهت اطمینان از عدم وجود رکوردهای تکراری، گزارش مدیریتی اصلی با نام rpt_TopCustomers طراحی گردید. برای تسهیل تصمیم‌گیری‌های مدیریتی، در سطح طراحی این گزارش و نه در سطح پرس‌وجو، از قابلیت قالب‌بندی شرطی^۴ بهره گرفته شد؛ به طوری که ارزش‌های خرید فراتر از ۵۰,۰۰۰ با رنگ سبز و مقادیر کمتر از ۱۰,۰۰۰ با رنگ قرمز برجسته شدند تا مشتریان کلیدی و مشتریان با پتانسیل خرید پایین بلافاصله قابل تفکیک باشند.

Top Customers Analysis		
CustomerID	SalesAmount	TotalPurchase
QUICK	86	\$110,277.31
ERNSH	102	\$104,874.98
SAVEA	116	\$104,361.95
RATTC	71	\$51,097.80
HUNGO	55	\$49,979.91
HANAR	32	\$32,841.37
KOENE	39	\$30,908.38
FOLKO	45	\$29,567.56
MEREP	32	\$28,872.19
WHITC	40	\$27,363.61
FRANK	48	\$26,656.56
QUEEN	40	\$25,717.50
BERGS	52	\$24,927.58
SUPRD	39	\$24,088.78
PICCO	23	\$23,128.86
HILAA	45	\$22,768.76

شکل ۵۹: نمایی از گزارش تهیه شده براساس مجموع خرید مشتریان

Report2_CustomersListOnTotalPurchase		
CustomerID	CountOfOrder	TotalPurchase
QUICK	86	\$110,277.31
ERNSH	102	\$104,874.98
SAVEA	116	\$104,361.95
RATTC	71	\$51,097.80
HUNGO	55	\$49,979.91
HANAR	32	\$32,841.37
KOENE	39	\$30,908.38
FOLKO	45	\$29,567.56
MEREP	32	\$28,872.19
WHITC	40	\$27,363.61
FRANK	48	\$26,656.56
QUEEN	40	\$25,717.50
BERGS	52	\$24,927.58
SUPRD	39	\$24,088.78
PICCO	23	\$23,128.86
HILAA	45	\$22,768.76
BONAP	44	\$21,963.25
BOTTM	35	\$20,801.60
RICSU	30	\$19,343.78
LEHMS	39	\$19,261.41
BLONP	26	\$18,534.08
GREAL	22	\$18,507.45
SIMOB	15	\$16,817.10
LINOD	35	\$16,476.57
SEVES	26	\$16,215.33
LILAS	34	\$16,076.60
VAFFE	31	\$15,843.93
WARTH	37	\$15,648.70
OLDWO	24	\$15,177.46

شکل ۵۸: خروجی به ترتیب مجموع خرید مشتریان

¹ Targeted Marketing

² OrderID

³ Descending

⁴ Conditional Formatting

در گام بعدی و برای تکمیل این زنجیره تحلیلی، پرس‌وجو و گزارش موازی دیگری با تمرکز بر تعداد دفعات خرید توسعه یافت تا مشتریان وفادار^۱ شناسایی شوند. در این بخش، منطق گروه‌بندی مجدداً بر روی شناسه مشتری اعمال و شمارش سفارش‌ها با تابع Count(OrderID) انجام شد. گزارش حاصل از این تحلیل نیز مجهز به قالب‌بندی شرطی گردید که در آن مشتریانی با بیش از ۵۰ سفارش با رنگ سبز و مشتریانی با کمتر از ۱۰ سفارش با رنگ قرمز نمایش داده شدند.

Top Customers Analysis		
CustomerID	Sale Amount	TotalPurchase
SAVEA	116	\$104,361.95
ERNSH	102	\$104,874.98
QUICK	86	\$110,277.31
RATTC	71	\$51,097.80
HUNGO	55	\$49,979.91
BERGS	52	\$24,927.58
FRANK	48	\$26,656.56
FOLKO	45	\$29,567.56
HILAA	45	\$22,768.76
BONAP	44	\$21,963.25
QUEEN	40	\$25,717.50
WHITC	40	\$27,363.61
KOENE	39	\$30,908.38
LEHMS	39	\$19,261.41
SUPRD	39	\$24,088.78
WARTH	37	\$15,648.70

CustomerID	CountOfOrder	TotalPurchase
SAVEA	116	\$104,361.95
ERNSH	102	\$104,874.98
QUICK	86	\$110,277.31
RATTC	71	\$51,097.80
HUNGO	55	\$49,979.91
BERGS	52	\$24,927.58
FRANK	48	\$26,656.56
FOLKO	45	\$29,567.56
HILAA	45	\$22,768.76
BONAP	44	\$21,963.25
QUEEN	40	\$25,717.50
WHITC	40	\$27,363.61
KOENE	39	\$30,908.38
LEHMS	39	\$19,261.41
SUPRD	39	\$24,088.78
WARTH	37	\$15,648.70
LINOD	35	\$16,476.57
BOTTM	35	\$20,801.60
LILAS	34	\$16,076.60
MEREP	32	\$28,872.19
HANAR	32	\$32,841.37
VAFFE	31	\$15,843.93
LAMAI	31	\$9,328.20
AROUT	30	\$13,390.65
RICSU	30	\$19,343.78
TORTU	29	\$10,812.15
OTTIK	29	\$12,496.20
RICAR	27	\$12,450.80
GODOS	26	\$11,446.36

شکل ۶۱: نمایی از گزارش تهیه شده براساس مجموع خرید مشتریان

شکل ۶۰: خروجی به ترتیب مجموع خرید مشتریان

در ادامه و به‌منظور تکمیل چارچوب تحلیلی رفتار مشتریان، دو گزارش مکمل دیگر نیز طراحی و پیاده‌سازی گردید. گزارش نخست به شناسایی ۱۰ درصد برتر مشتریان از نظر میزان خرید اختصاص یافت؛ به این صورت که مشتریان بر مبنای فیلد TotalPurchase به‌صورت نزولی رتبه‌بندی شده و با استفاده از قابلیت Top Values در سطح پرس‌وجو، تنها مشتریانی که در بالاترین دهک ارزش خرید قرار داشتند استخراج شدند. منطق این گزارش بر آن استوار است که بهره‌گیری از یک معیار نسبی به‌جای یک آستانه ثابت مالی، دقت بیشتری در شناسایی مشتریان کلیدی فراهم می‌آورد؛ زیرا در این روش، انتخاب مشتریان برتر متناسب با توزیع واقعی داده‌ها و ساختار خرید در جامعه مشتریان انجام می‌شود. این رویکرد از منظر بازاریابی، برای طراحی کمپین‌های هدفمند، تخصیص بهینه مشوق‌های فروش، شناسایی مشتریان با ارزش بالا و تمرکز بر مشتریان دارای بیشترین ظرفیت سودآوری، اهمیت ویژه‌ای دارد.

همچنین، پرس‌وجو و گزارش مستقلی نیز برای استخراج ۱۰ درصد برتر مشتریان از نظر تعداد دفعات خرید طراحی گردید تا مشتریان وفادار و دارای تکرار خرید بالا با دقت بیشتری شناسایی شوند. در این گزارش، مبنای رتبه‌بندی بر اساس فیلد شمارشی سفارش‌ها یعنی Count(OrderID) قرار گرفت و با اعمال منطق Top Values، تنها مشتریانی انتخاب شدند که از نظر دفعات مراجعه و تکرار خرید در بالاترین سطح قرار داشتند. ضرورت طراحی این گزارش از آن جهت است که در بسیاری از سناریوهای بازار، فراوانی خرید لزوماً با ارزش ریالی خرید یکسان نیست و ممکن است سفارش‌های متعدد، نقش مهم‌تری در پایداری تقاضا، گردش مستمر فروش و اثربخشی برنامه‌های وفادارسازی ایفا کنند. از این رو، این گزارش به‌عنوان ابزاری مکمل برای اجرای کمپین‌های نگهداشت مشتری، ارائه پیشنهادهای دوره‌ای، طراحی طرح‌های وفاداری و تحلیل رفتار مشتریان پرتکرار مورد استفاده قرار می‌گیرد.

^۱Frequent Buyers

Top Customers(10%)		
CustomerID	Totalorders	TotalPurchase
QUICK	86	\$110,277.31
ERNSH	102	\$104,874.98
SAVEA	116	\$104,361.95
RATTC	71	\$51,097.80
HUNGO	55	\$49,979.91
HANAR	32	\$32,841.37
KOENE	39	\$30,908.38
FOLKO	45	\$29,567.56
MEREP	32	\$28,872.19

Friday, July 3, 2026

Page 1 of 1

شکل ۶۳: ۱۰ درصد برتر مشتریان از لحاظ میزان خرید

Top Customers (10%)		
CustomerID	TotalOrders	TotalPurchase
SAVEA	116	\$104,361.95
ERNSH	102	\$104,874.98
QUICK	86	\$110,277.31
RATTC	71	\$51,097.80
HUNGO	55	\$49,979.91
BERGS	52	\$24,927.58
FRANK	48	\$26,656.56
FOLKO	45	\$29,567.56
HILAA	45	\$22,768.76

Friday, July 3, 2026

Page 1 of 1

شکل ۶۲: ۱۰ درصد برتر مشتریان از لحاظ تعداد خرید